

FlexTok：将图像重采样为灵活长度的一维 Token 序列

Roman Bachmann^{*1,2} Jesse Allardice^{*1} David Mizrahi^{*1} Enrico Fini¹ Oğuzhan Fatih Kar²
Elmira Amirloo¹ Alaaeldin El-Nouby¹ Amir Zamir² Afshin Dehghan¹

¹Apple (苹果公司) ²瑞士洛桑联邦理工学院 (EPFL)

<https://flextok.epfl.ch>




图 1: 部分序列生成对比: 光栅扫描二维网格 tokenizer 与 FlexTok。FlexTok 将图像重采样为灵活长度的一维离散 token 序列, 并以由粗到细的方式描述图像。当在 FlexTok token 序列上训练自回归 (AR) 模型时, 类别条件 (此处为“金毛寻回犬”) 最少只需生成 8 个 token 即可满足; 而在二维 tokenizer 网络上训练的 AR 模型 (此处为 LlamaGen (Sun et al., 2024)) 无论条件或图像复杂度如何, 都必须生成全部 token。

摘要

图像 token 化通过提供比原始像素更易于处理的压缩离散表示, 推动了自回归图像生成取得显著进展。传统方法通常采用二维网格 token 化, 而 TiTok 等近期方法表明, 通过消除网格中的冗余, 一维 token 化同样能够获得较高的生成质量。然而, 这些方法通常使用固定数量的 token, 因此无法根据图像自身的内在复杂度进行自适应调整。

本文提出 FlexTok, 一种能够将二维图像投影为可变长度、有序一维 token 序列的 tokenizer。例如, 一幅 256×256 图像可以被重采样为 1 至 256 个任意长度的离散 token, 从而以分层且语义化的方式压缩图像信息。通过将校正流 (rectified flow) 模型作为解码器并采用嵌套 dropout, FlexTok 无论选取何种 token 序列长度, 都能够生成合理的重建

图像。

我们使用一个简单的 GPT 风格 Transformer, 在自回归生成设置下评估所提出的方法。在 ImageNet 上, 该方法在 8 至 128 个 token 的范围内均达到 $FID < 2$, 优于 TiTok, 并且仅使用更少的 token 即可达到与当前先进方法相当的性能。我们进一步将模型扩展到文本条件图像生成, 并研究 FlexTok 与传统二维 token 化之间的关系。一个关键发现是, FlexTok 使下一 token 预测能够利用由粗到细的“视觉词汇”来描述图像, 并且所需生成的 token 数量取决于生成任务的复杂度。

1. 引言

图像生成在生成质量和推理速度方面均取得了显著进展。Token 化通过降低生成模型的训练计算成本发挥着关键作用 (Van Den Oord et al., 2017; Esser et al., 2021)。近期, 自回归 (AR) 图像生成在扩展到数十亿参数后已经表现出具有竞争力的性能 (Sun et al., 2024)。

扩散模型 (Rombach et al., 2022; Peebles & Xie, 2023)、

* 共同贡献。通讯作者: Roman Bachmann <roman.bachmann@epfl.ch>, Jesse Allardice <jallardice@apple.com>, David Mizrahi <d_mizrahi@apple.com>。




图 2: 在 DFN 上训练的 FlexTok d18-d28 的重建示例。可以看到, 大多数图像的语义和几何内容使用不到 16 个 token 即可捕获。最前面的 token 已经能够表示高层语义概念 (例如灰色鸟类、身着彩色服装的人群、山地场景、黄色花朵), 而重建更复杂的场景细节则需要更多 token (例如每个人的位置和服饰、笔触位置等)。为了展示分布外重建能力, 我们使用 Midjourney v6.1 (Midjourney, 2024) 生成原始图像。

掩码模型 (Chang et al., 2022; 2023) 和自回归模型 (Chen et al., 2020; Yu et al., 2022) 等生成模型传统上通常在连续或离散 token 构成的二维网格上运行。这些表示与原始像素块保持很强的空间对齐关系 (Esser et al., 2021; Mentzer et al., 2023), 但这也意味着表示规模与图像尺寸成正比, 而不是由图像复杂度决定。近期工作 (Yu et al., 2024a) 已证明, 一维 token 化方案能够在保持具有竞争力质量的同时提高计算效率。与现有二维网格 token 化方案类似, 这些一维 token 序列仍然是固定长度的, 并不考虑底层图像的复杂度。换言之, 无论图像只是简单地描绘单个物体, 还是包含大量复杂细节的繁忙场景, 都会被编码为相同数量的 token。因此, 为预测这些 token 而训练的条件图像生成器无论条件的语义复杂度如何, 都必须始终生成完整的一组 token。

本文提出 FlexTok, 一种新型可变长度一维 tokenizer, 能够将图像编码为有序且依赖于内容的 token 序列。如图 2 所示, 前面的 token 捕获最高层的语义和几何信息, 随后增加的 token 则逐步补充更加精细的细节。长度为 1、2、4、...、256 的截断子序列均可通过端到端训练的校正流解码器解码为合理的图像。图 1 对比了传统二维 tokenizer 刚性的光栅扫描顺序 (上) 与我们支持由粗到细生成的分层一维方案 (下)。

本文的主要贡献如下:

灵活长度 token 化: 我们提出一种一维 token 化方法, 可将图像压缩为 1 至 256 个任意数量的 token。通过结合嵌套 dropout 与因果注意力掩码, 所得到的 token 能够自然地按照由粗到细的细节顺序排列, 从而即使仅使用极少量 token 也能实现高质量重建, 并随

着 token 数量增加逐步提供更加详细的表示。

用于描述图像的新型“视觉词汇”: 与在每个 x, y 位置描述图像内容的经典二维 tokenizer 不同, FlexTok 采用一种分层方式, 使语义和几何概念等高层信息自然地优先出现, 而后续 token 则逐渐补充更细粒度的细节。因此, 较粗略的条件只需预测较少 token 即可满足, 而更详细的条件则需要生成更多 token。例如, 如图 7 所示, ImageNet-1k 类别仅需 8 个 token 即可生成。相比之下, 文本条件可能包含更加复杂且多样的提示, 因此生成多达 256 个 token 仍可带来收益。

端到端训练的校正流解码器: 为了在不同 token 长度下都实现高质量图像重建, 我们在 tokenizer 解码器中引入校正流目标。该架构对于在极高压缩率下仍保持重建质量至关重要。

2. 相关工作与背景

图像 tokenizer 在生成任务中的主要作用是构建图像的压缩潜在表示。生成模型需要学习输出的概率分布, 但直接在连续、高维空间 (例如原始图像像素) 中进行学习非常困难。压缩通过将图像映射到更紧凑、去除难以感知细节的潜在空间来缓解这一问题 (Rombach et al., 2022); 离散化则使生成模型能够针对每个 token 输出可采样的类别分布。

向量量化自编码器 (VQ-VAE) (Van Den Oord et al., 2017; Razavi et al., 2019; Esser et al., 2021) 已成为学习此类离散表示的标准框架。VQ-VAE 模型由三个核心组件构成: (1) 编码器 Enc , 将输入图像 $X \in$

$\mathbb{R}^{H \times W \times 3}$ 映射为 D 通道潜在嵌入 $\mathbf{Z} = \text{Enc}(\mathbf{X}) \in \mathbb{R}^{h \times w \times D}$ (通常 $h \ll H$ 且 $w \ll W$) ; (2) 量化器 Quant , 将这些连续潜变量映射到从学习得到的码本中选取的离散码; 以及 (3) 解码器 Dec , 用于重建图像 $\hat{\mathbf{X}} = \text{Dec}(\text{Quant}(\mathbf{Z}))$ 。该方法具有很强的通用性, 已应用于图像 (Chang et al., 2022; 2023; Li et al., 2022)、音频 (Baevski et al., 2019) 和视频生成 (Villegas et al., 2022; Hu et al., 2023; Kondratyuk et al., 2023)、新视角合成 (Yan et al., 2021) 以及大规模多模态预训练 (Lu et al., 2022; 2023; Mizrahi et al., 2023; Bachmann et al., 2024; Chameleon, 2024; Wang et al., 2024a)。

已有大量工作从不同方向改进这一框架, 包括探索不同架构 (Yu et al., 2021)、目标函数 (Esser et al., 2021; Hu et al., 2023)、码本结构 (Zhang et al., 2023; Yu et al., 2023), 以及使用扩散模型作为解码器 (Shi et al., 2022; Mizrahi et al., 2023; Xu et al., 2024; Zhao et al., 2024)。其中一个重要进展是有限标量量化 (FSQ) (Mentzer et al., 2023), 其使用到低维潜在空间的投影代替学习式码本, 并沿各维使用固定量化级对数值进行量化。该方法在保持重建质量的同时, 实现和训练都更加简单。

不同于在潜在空间中保持二维空间结构, TiTok (Yu et al., 2024a) 使用学习得到的寄存器 token $\mathbf{R} \in \mathbb{R}^{K \times D}$ (Darcet et al., 2023) 构建一维表示。在编码过程中, K 个寄存器 token 与图像 patch 嵌入 $\mathbf{P} \in \mathbb{R}^{h \times w \times D}$ 拼接后输入 ViT 编码器。编码器输出仅保留寄存器 token 嵌入作为 $\mathbf{Z}_{1D}$, 以紧凑序列形式捕获图像内容。进行重建时, 图像 patch 被替换为一个由 $h \times w$ 个可学习掩码 token $\mathbf{M} \in \mathbb{R}^{h \times w \times D}$ 构成的网格。在量化寄存器嵌入的引导下, 这些掩码 token 由解码器转换为重建图像: $\hat{\mathbf{X}} = \text{Dec}(\text{Quant}(\mathbf{Z}_{1D}) \oplus \mathbf{M})$ 。

尽管 TiTok 能够有效生成一维 token 序列, 但其需要两阶段训练, 并且仍使用固定数量的 token 表示图像。与 TiTok 相比, FlexTok 在重建和生成质量方面均表现更好 (见 图 4 和表 1)。为解决 token 序列长度完全由图像高宽而非图像复杂度决定的问题, 一系列同期工作提出了自适应 token 化方法。FlexTok 最少可将图像压缩到单个 token, 而 ElasticTok (Yan et al., 2024) 的 FSQ tokenizer 最少仍需要 256 个 token, ALIT (Duggal et al., 2024) 则最少需要 32 个 token。生成是 tokenizer 的关键应用之一; 与 ElasticTok、ALIT 或 One-D-Piece (Miwa et al., 2025) 不同, 我们在第 5 节中证明, 基于 FlexTok token 进行训练可以得到性能强劲的生成模型。相比本文对 AR 模型的关注, ViLex (Wang et al., 2024b) 和 CAT (Shen et al., 2025) 更侧重学习用于扩散模型的连续 token。我们在第 D 节中进一步详细讨论这些方法与 FlexTok 的差异。

3. 方法

FlexTok 是一个具有离散一维瓶颈的自编码器, 其总体结构如图 3 所示。ViT 编码器利用寄存器 token (Darcet et al., 2023; Yu et al., 2024a) 将二维图像 patch 映射为一维序列。寄存器随后经 FSQ (Mentzer et al., 2023) 离散化, 并作为校正流模型的条件, 用于重建图像。我们在寄存器 token 之间采用因果注意力, 并进一步应用嵌套 dropout (Rippel et al., 2014), 从而在瓶颈表示中诱导出有序结构。结合校正流解码器后, 该设计使模型能够从任意嵌套 token 子集解码得到合理的图像。

3.1. 基于校正流解码器的一维 token 化

寄存器编码器与离散瓶颈。 与 TiTok (Yu et al., 2024a) 类似, 编码器使用寄存器 token 将经过 patch 化的二维 VAE 潜变量重采样为一维离散 token 序列。具体而言, 我们将 VAE 潜变量 patch 与一组可学习寄存器 token 拼接, 后者充当编码器中的读写存储单元。编码完成后, 寄存器 token 作为自编码器的瓶颈表示, 而编码后的 patch 被丢弃。随后使用 FSQ 将寄存器 token 量化为离散 token。我们并不直接在像素空间上操作, 而是类似 SDXL 的 VAE (Podell et al., 2023), 使用 VAE-GAN 的潜在表示, 从而将感知压缩从本文研究问题中抽离。由于直接在像素上训练生成模型的计算开销很大 (Rombach et al., 2022), 采用 VAE-GAN 潜在空间能够大幅简化设计空间并降低计算需求。

校正流解码器。 解码器的目标是在压缩潜在表示的条件下生成感知上合理的图像。当瓶颈尺寸较小时, 仅使用重建损失训练解码器容易产生模糊重建。为缓解这一问题, FlexTok 使用校正流模型, 并通过将量化后的寄存器 token $\text{Quant}(\mathbf{Z}_{1D})$ 与加噪 VAE 潜变量 patch $\mathbf{X}_t = (1-t)\mathbf{X}_0 + t\epsilon$ 拼接来进行条件化, 其中 $\mathbf{X}_0$ 为干净的 VAE 潜变量, $t \in [0, 1]$ 为随机时间步, $\epsilon \sim \mathcal{N}(0, 1)$ 为从噪声分布中采样的随机样本。给定部分加噪的 VAE 潜变量和编码后的寄存器 token, 解码器的目标是预测流 $\mathbf{U} = \epsilon - \mathbf{X}_0$ 。对于预测流 $\hat{\mathbf{U}} = \text{Dec}(\text{Quant}(\mathbf{Z}_{1D}) \oplus \mathbf{X}_t)$, 我们最小化校正流损失 $\mathcal{L}_{\text{RF}} = \|\hat{\mathbf{U}} - (\epsilon - \mathbf{X}_0)\|^2$ 。我们发现, 在某个中间解码器层与 DINOv2-L (Oquab et al., 2023) 特征之间加入 REPA (Yu et al., 2024b) 归纳偏置损失 $\mathcal{L}_{\text{REPA}}$, 能够显著改善收敛速度和下游生成性能 (见 表 3 和图 12)。最终优化的 FlexTok 总损失为 $\mathcal{L}_{\text{FlexTok}} = \mathcal{L}_{\text{RF}} + \lambda_{\text{REPA}} \cdot \mathcal{L}_{\text{REPA}}$, 其中 $\lambda_{\text{REPA}} = 1$ 。更多实现细节见第 4 节和第 C.2 节。

3.2. 学习灵活长度的有序一维 token 序列

TiTok (Yu et al., 2024a) 等一维 tokenizer 需要针对不同的寄存器 token 数量分别训练不同 tokenizer。同期工作 ALIT (Duggal et al., 2024) 表明, 固定 token 序列长度无法考虑图像本身的内在复杂度: 简单图像只需约 32 个 token 即可忠实压缩, 而复杂图像则需要更




图 3: FlexTok 概览。阶段 1: FlexTok 使用带寄存器的 ViT (Darcet et al., 2023) 将二维 VAE 潜变量重采样为一维离散 token 序列。经过 FSQ 量化 (Mentzer et al., 2023) 的瓶颈表示用于条件化一个校正流模型, 由该模型对原始图像进行解码和重建。FlexTok 通过对寄存器 token 应用嵌套 dropout (Rippel et al., 2014), 学习具有灵活长度的有序 token 序列。阶段 2: 我们训练类别条件和文本条件的自回归 Transformer, 以由粗到细的方式预测一维 token 序列。随着预测 token 数量增加, 生成图像变得更加具体, 模型首先编码高层概念 (例如存在一辆汽车), 随后再编码更细的细节 (例如汽车形状、品牌和颜色)。

多 token 才能准确重建。TiTok 和 ALIT 都没有展示低于 32 个 token 的灵活 token 化, 并且在高压缩率下图像重建性能会明显下降; 与 FlexTok 的视觉对比见图 4 和第 K.3 节。由于本文使用 FlexTok 面向 AR 生成, 我们进一步引入从左到右的嵌套有序结构, 使其天然适配下一 token 预测。具体而言, 我们提出以下两种技术, 用于为 token 序列引入一维顺序和可变长度。

嵌套 dropout。 我们在训练期间以嵌套方式随机丢弃编码后的寄存器 token, 从而训练 FlexTok 产生有序表示 (Rippel et al., 2014; Kusupati et al., 2022; Cai et al., 2024)。具体地, 给定长度为 K 的寄存器 token 序列, 我们随机采样保留单元数量 $K_{keep} \in \{1, \dots, K\}$, 并通过掩码移除最后的 $K - K_{keep}$ 个 token。通过这种训练方式, 编码器学习按一定顺序将图像内容压缩到寄存器 token 中, 而校正流解码器则学习从不同长度的 token 序列重建图像。如图 5 所示, 该设计使 FlexTok 能够仅用极少 token 捕获图像中最重要的信息。简单图像只需少量 token 即可被忠实压缩, 而复杂图像则需要更长的 token 序列。需要强调的是, 这种顺序并非人工设计, 而是仅通过对寄存器 token 施加嵌套 dropout, 并计算校正流和 REPA 损失自然涌现的。我们主要消融两种嵌套丢弃 token 的策略。第一种如上所述, 对保留 token 数量进行均匀采样。第二种则从指数增长的集合中进行均匀采样, 例如 $K_{keep} \in \{1, 2, 4, 8, 16, \dots, K\}$ 。后一种变体解决了均匀嵌套 dropout 的一个问题: 靠后的寄存器 token 很少被传递给解码器, 因此实际上只参与了很少一部分梯度更新。

因果注意力掩码。 与嵌套 dropout 相互独立地, 我们还对编码后的寄存器加入因果注意力掩码, 从而在寄存器之间强制形成因果依赖结构 (Ge et al., 2023)。在该设置下, 编码后的图像 patch 可以彼此注意, 但不能注意寄存器; 寄存器 token 可以注意所有 patch, 但第 i 个寄存器 token 仅当 $i \geq j$ 时才能注意第 j 个

寄存器 token。此外, 使用因果掩码还使用户能够在预先知道仅希望保留 $K_{keep} \ll K$ 个 token 时, 更高效地对图像进行编码。

3.3. 自回归图像生成

为了评估 FlexTok 的不同设计选择并与相关基线进行比较, 我们同时测量重建性能和生成性能。为此, 我们遵循 LlamaGen (Sun et al., 2024), 训练自回归 Transformer 在 ImageNet-1k (Russakovsky et al., 2014) 上进行类别条件生成, 并在 DFN-2B (Fang et al., 2023) 上进行文本到图像生成。

4. 实现细节

我们将整体实现划分为三个相互独立的阶段。在阶段 0 中, 我们训练具有连续潜变量的 VAE 模型 (Rombach et al., 2022), 将图像感知压缩为二维 token 网格。在阶段 1 中, 我们进一步训练 FlexTok tokenizer, 将这些连续二维 token 网格重采样为灵活长度的一维离散 token 序列。最后, 在阶段 2 中, 我们训练自回归类别到图像模型和文本到图像模型, 以评估 FlexTok 在生成任务中的有效性。

阶段 0: VAE 训练。 校正流解码器 (见第 3.1 节) 是 FlexTok 的关键设计之一, 使其能够对任意 token 子序列进行解码。然而, 直接在像素空间中训练这类模型的计算成本很高 (Rombach et al., 2022)。因此, 该阶段的目标是通过将图像感知压缩为更加紧凑的表示, 降低阶段 1 的建模难度。我们采用 SDXL VAE (Podell et al., 2023) 的架构, 并在 DFN 数据集 (Fang et al., 2023) 上训练 4、8 和 16 通道版本。后续所有实验均使用 16 通道、下采样因子为 8 的 VAE。更多 VAE 训练细节见第 C.1 节, 不同潜在通道数的消融实验见表 2。




图 4: 三种不同 TiTok (Yu et al., 2024a) 模型、ALIT (Duggal et al., 2024) 与 FlexTok 的图像重建对比。与其他一维 tokenizer 相比, FlexTok 能够以高度语义化且有序的方式对图像进行 token 化, 最低可压缩至单个 token, 而且所有长度均由同一个模型实现。更多视觉对比见 第 K.1-K.3 节。




图 5: FlexTok 的率失真权衡。我们给出了三种不同规模 FlexTok 在 ImageNet-1k 上的重建指标。使用的 token 越多, 重建结果就越接近原始 RGB 图像。增大 tokenizer 规模能够显著改善重建 FID, 但对 MAE 和 DreamSim 分数的影响相对较小。对于不同规模的 FlexTok 模型, 我们均采用 第 F 节 中给出的最优推理超参数。更多重建指标见 表 8。

阶段 1: FlexTok 训练。 FlexTok 架构由 Transformer 编码器和解码器构成, 最多使用 256 个寄存器 token。编码后的寄存器首先经过 6 维 FSQ (Mentzer et al., 2023) 瓶颈, 其量化级别为 [8, 8, 8, 5, 5, 5] (对应有效词表大小 64000), 随后通过嵌套 dropout 对寄存器进行随机截断。解码器是一个校正流模型, 以加噪 VAE 潜变量 patch 和 (随机掩码后的) 寄存器为输入, 并负责预测流。我们使用 adaLN-zero (Peebles & Xie, 2023), 针对当前时间步分别对 patch 和寄存器进行条件化, 并使用基于 DINOv2-L (Oquab et al., 2023) 特征的 REPA (Yu et al., 2024b) 加速收敛。FlexTok 的编码器和解码器均采用 2×2 patch 化, 与 VAE 的 8 倍下采样结合后, 从像素到 patch token 的总下采样倍数为 16。所有模型均在 256×256 像素分辨率下训练。编码器和解码器维度 w 分别由其深度 d 参数化, 并采用固定宽深比 64, 即 $w = 64 \cdot d$ 。在小规模上利用 μP (Yang et al., 2022) 搜索最优超参数后, 我们训练三种不同编码器/解码器规模 (用连字符分隔) 的 FlexTok: d12-d12、d18-d18 和 d18-d28。根据下游用途, 我们分别在 ImageNet-1k (Russakovsky et al., 2014) 上训练用于后续类别条件生成的 FlexTok 模型, 在 DFN (Fang et al., 2023) 上训练用于后续文本到图像建模的模型。更多 FlexTok 实现与训练细节

见 第 C.2 节。

阶段 2: AR Transformer 训练。 我们的自回归 Transformer 遵循 LlamaGen 的类 Llama 架构 (Sun et al., 2024; Touvron et al., 2023), 使用基于 RM-SNorm (Zhang & Sennrich, 2019) 的预归一化和 SwiGLU 前馈网络 (Shazeer, 2020)。由于我们的 token 不具有二维网格结构, 因此使用学习式绝对位置嵌入, 而不是二维 RoPE (Su et al., 2024)。

对于类别条件生成, 我们将学习得到的类别嵌入加入到 [SOI] token (Tian et al., 2024) 上, 并将其与图像 token 序列拼接。参数量从 49M 到 1.3B 的 AR 模型负责预测来自 FlexTok tokenizer 的 token 序列。为了便于与 LlamaGen 和 TiTok 对比, 我们训练时不使用 μP 。

对于文本条件生成, AR 解码器通过交叉注意力使用 FLAN-T5-XL (Chung et al., 2024) 的文本嵌入, 并通过一个 MLP (Chen et al., 2023) 将其投影到模型维度。我们将这些文本条件 AR 模型扩展到最高 3B 参数, 并使用 μP 以维持不同规模模型间的一致行为。

遵循常见做法, 我们在训练期间采用条件 dropout, 以便推理时使用无分类器引导。对于文本条件模型, 这具体表现为随机将文本输入替换为空字符串。更多实

现和训练细节见第 C.3 节。

5. 实验

本节通过实验评估 FlexTok 在不同 token 数量下的重建性能，考察其用于类别条件和文本条件图像生成的适用性，并与相关基线进行比较。结果表明，FlexTok 能够有效地将图像压缩为灵活长度的一维序列，从而形成一种新型“视觉词汇”：图像能够以由粗到细的方式被逐步描述和生成。

5.1. 灵活长度 token 化

我们通过评估不同长度嵌套 token 序列上的重建性能，验证 FlexTok 的可变码率 token 化能力。比较时使用在 ImageNet-1k 上训练的 FlexTok 模型，并在验证集中的 256×256 像素裁剪图像上进行测试 (Russakovsky et al., 2014)。在图 5 中，我们针对 $K_{\text{keep}} \in \{1, 2, 4, 8, 16, \dots, 256\}$ 个 token 测量重建指标 (rFID、MAE 和 DreamSim)。从相对于 ImageNet-1k 验证集计算的 rFID 可以看出，即使仅使用单个 token，FlexTok 仍然能够生成合理的图像。

如图 2 中在 DFN 上训练的 FlexTok d18-d28，以及图 4 中在 ImageNet-1k 上训练的 FlexTok d18-d28 所示，仅使用最前面的少量 token 进行重建时，就已经能够捕获高层语义特征。随着使用的 token 增多，重建结果与原始图像之间的对齐变得更加细粒度，并且逐图像的重建指标 (MAE 和 DreamSim) 也快速改善。

更多重建示例和对比如第 K.1-K.3 节。Token 序列上的线性探测实验见第 B 节。

我们认为以下性质尤其值得关注：(1) 通过对寄存器执行嵌套 dropout，会自然涌现出高层概念优先排列的层级结构；(2) 通过使用校正流解码器训练 FlexTok，任意 token 子序列均可被解码为合理图像；(3) token 序列刻画了一个图像分布，并且随着 token 数量增加，该分布会变得越来越具体。相关视觉示例见图 34 和 35。

5.2. 具体性逐步增强的由粗到细生成

如第 5.1 节所示，FlexTok 将图像压缩为有序 token 序列。这自然促使我们进一步研究在自回归图像生成中预测这些序列会带来怎样的效果。通过训练类别条件和文本条件模型，我们发现 FlexTok token 序列可以充当一种“视觉词汇”，使自回归模型能够以逐渐增强的具体程度描述图像。传统自回归模型需要按照二维 token 网格中的固定光栅扫描顺序生成图像，而我们的方法可以逐步细化图像细节。我们还观察到条件复杂度与 token 需求之间存在清晰关系。ImageNet 类别标签等简单条件仅需约 16 个 token 即可满足，而开放式文本提示等更复杂条件则可从生成多达 256 个 token 中获益。

在图 6 中，我们展示了随着生成 token 数量增加，类别条件或文本条件模型生成的图像会越来越具体地符

合其条件。图 7 中的定量结果进一步验证了这一趋势：随着 token 数量增加，条件信号与生成图像之间的对齐程度持续提高。对于类别条件，我们使用 DINOv2-L (Oquab et al., 2023) 分类准确率衡量对齐；对于文本条件，则使用 CLIPScore。值得注意的是，文本-图像对齐会随着更多 token 的生成持续改善，而分类准确率在最初几个 token 后增幅逐渐变小，并在约 32 个 token 处进入平台期 (图 7 和 9)。此外，以 gFID 衡量时，我们观察到生成质量在各种 token 序列长度下均保持稳定，这主要得益于校正流解码器的强大能力。

类似地，图 8 表明，生成与提示词对齐的图像所需 token 数量会随提示词复杂度显著变化。对于“一个红苹果”这样的简单提示词，仅使用 4 至 16 个 token 就能产生令人满意的结果；而对于“火箭飞船的涂鸦”这样的详细提示词，则使用完整 256-token 序列更有优势。当使用较少 token 时，模型仍能生成逼真图像，但不同随机种子之间的差异更大。随着 token 数量增加，这种差异在简单提示词下比详细提示词下消失得快得多，说明提示词复杂度与 token 需求之间可能存在一种基本关系。

5.3. 自回归模型规模扩展

如图 7 所示，对于我们最大的自回归模型，条件与生成结果之间的对齐通常会随着预测 token 增多而改善。本节研究在 FlexTok d18-d28 token 上训练的自回归类别条件模型的规模扩展行为，重点分析模型规模如何影响图像-文本对齐和图像保真度。图 9 表明，增大 AR 模型规模能够稳定降低训练损失。然而，对于最前面的少量 (1-8) token，解码图像的生成 FID (gFID) 实际上基本不受自回归模型规模影响，说明即使较小模型也很容易学习序列开头的这些短片段。相比之下，对于较长序列 (> 128 个 token)，任务难度明显增加，gFID 和 CLIPScore 均随模型规模呈现出明显的扩展收益。

这揭示了 FlexTok 与 AR 模型之间一个重要的权衡关系：随着生成 token 数量增加，AR 模型在塑造图像中的作用也会增大。当 token 较少时，FlexTok 的流解码器主导大部分生成过程，因此即使搭配较小 AR 模型也能获得较低的 gFID；但随着 token 数量增加，为维持良好性能，就需要同样强大的 AR 模型。

5.4. 系统级比较

在表 1 中，我们将 FlexTok 模型与多个相关基线进行比较。具体而言，通过训练自回归模型完成 ImageNet-1k 类别条件生成来评估不同 tokenizer。与已有一维方案相比，FlexTok 在各个 token 预算下均能获得更优的重建和生成质量，而且这些能力全部由同一个模型实现。

作为对照，我们训练了一个带流匹配解码器的二维网格 tokenizer，其参数量、训练步数和源数据集均与 FlexTok d18-d28 保持一致。与 FlexTok d18-d28 不同，




图 6: 不同 token 数量下的图像生成示例。类别条件（上 3 行）和文本条件（下 3 行）的生成结果均表明，基于 FlexTok 的模型即使仅使用单个 token 也能保持较高生成质量，而且所有 token 长度均由同一个模型实现。随着生成 token 数量增加，生成结果与条件之间的对齐程度逐渐增强。例如，对于提示词“一只柯基犬的头部被描绘成星云爆炸”，前两个 token 已经捕获“一幅狗的艺术化描绘”这一高层概念，而增加更多 token 后则会进一步补充犬种和星云背景等细节。更多可视化结果见第 K.4 节、第 K.5 节。




图 7: 条件对齐程度和生成质量随 token 数量的变化。左：对于使用 1.3B AR 模型的类别条件生成，我们在以 ImageNet-1k 类别标签为条件生成的图像上计算 DINOv2-L (Oquab et al., 2023) top-1 准确率。中：对于使用 3B AR 模型的文本条件生成，我们基于一个 CLIP base 模型，给出相对于 COCO 30k 验证集 (Lin et al., 2014) 输入提示词的 CLIPScore。右：我们在 ImageNet-1k* 上测量类别条件 gFID，在 COCO 上测量文本条件 gFID。对应 AR 模型的引导尺度分别为 1.0（不使用引导）和 2.5。我们采用第 F 节、第 G 节中描述的最优推理参数。

* 注：在评估类别条件图像生成结果时，我们遵循常见做法，将 50K 个生成样本的生成 FID (gFID) 与基于 ImageNet-1k 数据集完整训练集计算得到的参考统计量进行比较 (Dhariwal & Nichol, 2021)。

该模型不使用寄存器 token、因果掩码或嵌套 dropout。当生成 2 至 128 个 token 时，使用 FlexTok tokenizer

的文本条件图像生成性能优于二维网格基线（图 7）。在完整的 256-token 序列下，尽管 FlexTok 的 gFID




图 8: 简单提示词与详细提示词下的图像生成。基于 FlexTok 的模型表明, 满足条件所需的 token 数量取决于提示词复杂度。对于简单提示词, 仅需 4-16 个 token 即可得到所需图像 (以 CLIPScore 衡量), 并且不同解码图像之间的语义差异 (以成对 DreamSim 分数衡量) 会迅速消失。相比之下, 详细提示词需要完整的 256-token 序列才能充分满足条件; 在 token 数量较少时, 由于 FlexTok 的校正流解码器会补偿缺失细节, 生成结果之间表现出更大的差异。对于每个提示词, FlexTok token 仅由 AR Transformer 生成一次, 随后在校正流解码器中使用 10 个不同随机种子进行解码。




图 9: 类别条件 AR 模型扩展。我们给出使用 FlexTok d18-d28 tokenizer 的类别条件模型的训练损失、gFID 和图像生成 CLIPScore。CLIPScore 使用 ImageNet-1k 验证集中的类别文本标签计算, 并且 AR Transformer 不使用无分类器引导 (CFG scale = 1.0)。1.33B AR 模型的更多生成指标见表 9。

相比二维网格模型略有下降, 但其文本-图像对齐程度 (CLIPScore) 仍优于二维网格 tokenizer。

6. 讨论与结论

本文展示了灵活序列长度 tokenizer 在图像重建与生成中的潜力。除能够仅使用极少 token 实现高保真重建之外, 我们还通过训练类别条件和文本条件 AR 模型证明, FlexTok token 序列构成了一种“视觉词汇”, 能够按照由粗到细的顺序进行生成。

实验结果表明, 根据生成任务的复杂度, 可以训练模型在条件得到满足后提前停止生成。虽然 FlexTok 能够将图像在语义层面压缩到最少单个 token, 但对于文本等高度密集或具有强结构的内容, 则需要更多 token 以及更加重视语义概念的训练目标。我们认为, 这些

方向为利用自适应计算预算加速并改进自回归图像生成提供了很有潜力的研究空间。

展望未来, 我们预计类似 FlexTok、能够根据输入数据内在复杂度自适应调整表示长度的 tokenizer, 也可以应用于音频和视频等高冗余模式。在既可高度紧凑且具语义性、又可扩展为长而细致的表示上训练生成模型, 有望进一步推动长时域视频生成、理解以及视觉推理等研究。

致谢

感谢 Justin Lazarow 和 Miguel Angel Bautista Martin 对本文早期版本提出的宝贵意见。本工作作为 Swiss AI initiative 的一部分, 由瑞士国家超级计算中心 (CSCS) Alps 平台项目 ID a08 提供资助。

表 1: ImageNet-1k 类别条件生成的系统级比较。FlexTok 可生成长度为 1–256 个 token 的可变长度 token 序列。FlexTok tokenizer 与 1.33B 参数的 AR Transformer 结合, 用于类别条件图像生成。对于每个 FlexTok 模型, 我们采用最优推理参数, 并且 AR 模型不使用无分类器引导, 具体设置见第 F 节、第 G 节。[†] 表示 FlexTok 在 32 个 token 序列上的结果。“-re” 后缀表示使用拒绝采样。

Tokenizer	# token	码本大小	rFID ↓	gFID ↓
Taming VQ-GAN-re	16x16	16384	4.98	5.20
MaskGIT VQ-GAN	16x16	1024	2.28	6.06
Open MAGVIT-v2	16x16	262144	1.17	2.33
LlamaGen	16x16	16384	2.19	3.06
TiTOK-L	32	4096	2.21	2.77
TiTOK-B	64	4096	1.70	2.48
TiTOK-S	128	4096	1.71	1.97
FlexTok d12-d12	1-256	64000	4.20 [†]	3.83 [†]
FlexTok d18-d18	1-256	64000	1.61 [†]	2.02 [†]
FlexTok d18-d28	1-256	64000	1.45 [†]	1.86 [†]

参考文献

- Bachmann, R., Kar, O. F., Mizrahi, D., Garjani, A., Gao, M., Griffiths, D., Hu, J., Dehghan, A., and Zamir, A. 4M-21: An any-to-any vision model for tens of tasks and modalities. *Advances in Neural Information Processing Systems*, 2024.
- Baevski, A., Schneider, S., and Auli, M. vq-wav2vec: Self-supervised learning of discrete speech representations. *arXiv preprint arXiv:1910.05453*, 2019.
- Burgess, N., Milanovic, J., Stephens, N., Monachopoulos, K., and Mansell, D. H. Bfloat16 processing for neural networks. 2019 IEEE 26th Symposium on Computer Arithmetic (ARITH), pp. 88–91, 2019. URL <https://api.semanticscholar.org/CorpusID:204819410>.
- Cai, M., Yang, J., Gao, J., and Lee, Y. J. Matryoshka multimodal models. *ArXiv*, abs/2405.17430, 2024. URL <https://api.semanticscholar.org/CorpusID:270063538>.
- Chameleon, T. Chameleon: Mixed-modal early-fusion foundation models. *arXiv preprint arXiv:2405.09818*, 2024.
- Chang, H., Zhang, H., Jiang, L., Liu, C., and Freeman, W. T. Maskgit: Masked generative image transformer. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 11305–11315, 2022. URL <https://api.semanticscholar.org/CorpusID:246680316>.
- Chang, H., Zhang, H., Barber, J., Maschinot, A., Lezama, J., Jiang, L., Yang, M., Murphy, K. P., Freeman, W. T., Rubinstein, M., Li, Y., and Krishnan, D. Muse: Text-to-image generation via masked generative transformers. *ArXiv*, abs/2301.00704, 2023. URL <https://api.semanticscholar.org/CorpusID:255372955>.
- Chen, J., Yu, J., Ge, C., Yao, L., Xie, E., Wu, Y., Wang, Z., Kwok, J., Luo, P., Lu, H., et al. Pixart- α : Fast training of diffusion transformer for photorealistic text-to-image synthesis. *arXiv preprint arXiv:2310.00426*, 2023.
- Chen, M., Radford, A., Wu, J., Jun, H., Dhariwal, P., Luan, D., and Sutskever, I. Generative pretraining from pixels. In *International Conference on Machine Learning*, 2020. URL <https://api.semanticscholar.org/CorpusID:219781060>.
- Chung, H. W., Hou, L., Longpre, S., Zoph, B., Tay, Y., Fedus, W., Li, Y., Wang, X., Dehghani, M., Brahma, S., et al. Scaling instruction-finetuned language models. *Journal of Machine Learning Research*, 25 (70):1–53, 2024.
- Darcet, T., Oquab, M., Mairal, J., and Bojanowski, P. Vision transformers need registers. *ArXiv*, abs/2309.16588, 2023. URL <https://api.semanticscholar.org/CorpusID:263134283>.
- Dhariwal, P. and Nichol, A. Diffusion models beat gans on image synthesis. *Advances in neural information processing systems*, 34:8780–8794, 2021.
- Dosovitskiy, A. and Brox, T. Generating images with perceptual similarity metrics based on deep networks. *Advances in neural information processing systems*, 29, 2016.
- Duggal, S., Isola, P., Torralba, A., and Freeman, W. T. Adaptive length image tokenization via recurrent allocation. 2024. URL <https://api.semanticscholar.org/CorpusID:273821611>.
- El-Nouby, A., Muckley, M., Ullrich, K., Laptev, I., Verbeek, J., and Jégou, H. Image compression with product quantized masked image modeling. *Trans. Mach. Learn. Res.*, 2023, 2022. URL <https://api.semanticscholar.org/CorpusID:263797879>.
- Esser, P., Rombach, R., and Ommer, B. Taming transformers for high-resolution image synthesis. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 12873–12883, 2021.
- Esser, P., Kulal, S., Blattmann, A., Entezari, R., Muller, J., Saini, H., Levi, Y., Lorenz, D., Sauer, A., Boesel, F., Podell, D., Dockhorn, T., English, Z., Lacey, K., Goodwin, A., Marek,

- Y., and Rombach, R. Scaling rectified flow transformers for high-resolution image synthesis. ArXiv, abs/2403.03206, 2024. URL <https://api.semanticscholar.org/CorpusID:268247980>.
- Fang, A., Jose, A. M., Jain, A., Schmidt, L., Toshev, A., and Shankar, V. Data filtering networks. arXiv preprint arXiv:2309.17425, 2023.
- Fini, E., Shukor, M., Li, X., Dufter, P., Klein, M., Haldimann, D., Aitharaju, S., da Costa, V. G. T., Béthune, L., Gan, Z., et al. Multimodal autoregressive pre-training of large vision encoders. arXiv preprint arXiv:2411.14402, 2024.
- Fu, S., Tamir, N. Y., Sundaram, S., Chai, L., Zhang, R., Dekel, T., and Isola, P. Dreamsim: Learning new dimensions of human visual similarity using synthetic data. ArXiv, abs/2306.09344, 2023. URL <https://api.semanticscholar.org/CorpusID:259171761>.
- Gal, R., Alaluf, Y., Atzmon, Y., Patashnik, O., Bermano, A. H., Chechik, G., and Cohen-Or, D. An image is worth one word: Personalizing text-to-image generation using textual inversion. ArXiv, abs/2208.01618, 2022. URL <https://api.semanticscholar.org/CorpusID:251253049>.
- Ge, Y., Ge, Y., Zeng, Z., Wang, X., and Shan, Y. Planting a seed of vision in large language model. ArXiv, abs/2307.08041, 2023. URL <https://api.semanticscholar.org/CorpusID:259937351>.
- Han, J., Liu, J., Jiang, Y., Yan, B., Zhang, Y., Yuan, Z., Peng, B., and Liu, X. Infinity: Scaling bitwise autoregressive modeling for high-resolution image synthesis. 2024. URL <https://api.semanticscholar.org/CorpusID:274515181>.
- Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., and Hochreiter, S. Gans trained by a two time-scale update rule converge to a local nash equilibrium. In Neural Information Processing Systems, 2017. URL <https://api.semanticscholar.org/CorpusID:326772>.
- Ho, J. Classifier-free diffusion guidance. ArXiv, abs/2207.12598, 2022. URL <https://api.semanticscholar.org/CorpusID:249145348>.
- Hoogeboom, E., Agustsson, E., Mentzer, F., Versari, L., Toderici, G., and Theis, L. High-fidelity image compression with score-based generative models. ArXiv, abs/2305.18231, 2023. URL <https://api.semanticscholar.org/CorpusID:258960316>.
- Hu, A., Russell, L., Yeo, H., Murez, Z., Fedoseev, G., Kendall, A., Shotton, J., and Corrado, G. Gaia-1: A generative world model for autonomous driving. ArXiv, abs/2309.17080, 2023. URL <https://api.semanticscholar.org/CorpusID:263310665>.
- Isola, P., Zhu, J.-Y., Zhou, T., and Efros, A. A. Image-to-image translation with conditional adversarial networks. In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1125–1134, 2017.
- Kolesnikov, A., Pinto, A. S., Beyer, L., Zhai, X., Harmsen, J., and Houlsby, N. Uvim: A unified modeling approach for vision with learned guiding codes. ArXiv, abs/2205.10337, 2022. URL <https://api.semanticscholar.org/CorpusID:248964962>.
- Kondratyuk, D., Yu, L., Gu, X., Lezama, J., Huang, J., Hornung, R., Adam, H., Akbari, H., Alon, Y., Birodkar, V., Cheng, Y., Chiu, M.-C., Dillon, J., Essa, I., Gupta, A., Hahn, M., Hauth, A., Hendon, D., Martinez, A., Minnen, D. C., Ross, D. A., Schindler, G., Sirotenko, M., Sohn, K., Somandepalli, K., Wang, H., Yan, J., Yang, M., Yang, X., Seybold, B., and Jiang, L. Videopoet: A large language model for zero-shot video generation. ArXiv, abs/2312.14125, 2023. URL <https://api.semanticscholar.org/CorpusID:266435847>.
- Kusupati, A., Bhatt, G., Rege, A., Wallingford, M., Sinha, A., Ramanujan, V., Howard-Snyder, W., Chen, K., Kakade, S. M., Jain, P., and Farhadi, A. Matryoshka representation learning. In Neural Information Processing Systems, 2022. URL <https://api.semanticscholar.org/CorpusID:252683450>.
- Li, T., Chang, H., Mishra, S. K., Zhang, H., Katabi, D., and Krishnan, D. Mage: Masked generative encoder to unify representation learning and image synthesis. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 2142–2152, 2022. URL <https://api.semanticscholar.org/CorpusID:253553243>.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. Microsoft coco: Common objects in context. In Computer Vision—ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6–12, 2014, Proceedings, Part V 13, pp. 740–755. Springer, 2014.
- Liu, X., Gong, C., and Liu, Q. Flow straight and fast: Learning to generate and transfer data with rectified flow. ArXiv, abs/2209.03003, 2022. URL <https://api.semanticscholar.org/CorpusID:252111177>.

- Loshchilov, I. and Hutter, F. Decoupled weight decay regularization. In International Conference on Learning Representations, 2017. URL <https://api.semanticscholar.org/CorpusID:53592270>.
- Lu, J., Clark, C., Zellers, R., Mottaghi, R., and Kembhavi, A. Unified-io: A unified model for vision, language, and multi-modal tasks. ArXiv, abs/2206.08916, 2022. URL <https://api.semanticscholar.org/CorpusID:249848272>.
- Lu, J., Clark, C., Lee, S., Zhang, Z., Khosla, S., Marten, R., Hoiem, D., and Kembhavi, A. Unified-io 2: Scaling autoregressive multimodal models with vision, language, audio, and action. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 26429–26445, 2023. URL <https://api.semanticscholar.org/CorpusID:266573555>.
- Ma, N., Goldstein, M., Albergo, M. S., Boffi, N. M., Vanden-Eijnden, E., and Xie, S. Sit: Exploring flow and diffusion-based generative models with scalable interpolant transformers. In European Conference on Computer Vision, 2024. URL <https://api.semanticscholar.org/CorpusID:267027717>.
- Mentzer, F., Toderici, G., Tschannen, M., and Agustsson, E. High-fidelity generative image compression. ArXiv, abs/2006.09965, 2020. URL <https://api.semanticscholar.org/CorpusID:219721015>.
- Mentzer, F., Minnen, D., Agustsson, E., and Tschannen, M. Finite scalar quantization: Vq-vae made simple. arXiv preprint arXiv:2309.15505, 2023.
- Midjourney. Midjourney version 6.1 update, 2024. URL <https://updates.midjourney.com/version-6-1/>.
- Miwa, K., Sasaki, K., Arai, H., Takahashi, T., and Yamaguchi, Y. One-d-piece: Image tokenizer meets quality-controllable compression. arXiv preprint arXiv:2501.10064, 2025.
- Mizrahi, D., Bachmann, R., Kar, O. F., Yeo, T., Gao, M., Dehghan, A., and Zamir, A. 4M: Massively multimodal masked modeling. In Advances in Neural Information Processing Systems, 2023.
- Oquab, M., Darcet, T., Moutakanni, T., Vo, H. Q., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y. B., Li, S.-W., Misra, I., Rabbat, M. G., Sharma, V., Synnaeve, G., Xu, H., Jégou, H., Mairal, J., Labetut, P., Joulin, A., and Bojanowski, P. Dinov2: Learning robust visual features without supervision. ArXiv, abs/2304.07193, 2023. URL <https://api.semanticscholar.org/CorpusID:258170077>.
- Peebles, W. and Xie, S. Scalable diffusion models with transformers. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 4195–4205, 2023.
- Podell, D., English, Z., Lacey, K., Blattmann, A., Dockhorn, T., Muller, J., Penna, J., and Rombach, R. Sdxl: Improving latent diffusion models for high-resolution image synthesis. ArXiv, abs/2307.01952, 2023. URL <https://api.semanticscholar.org/CorpusID:259341735>.
- Porian, T., Wortsman, M., Jitsev, J., Schmidt, L., and Carmon, Y. Resolving discrepancies in compute-optimal scaling of language models. arXiv preprint arXiv:2406.19146, 2024.
- PyTorch Team: Horace He, Driss Guessous, Yanbo Liang, Joy Dong. FlexAttention: The Flexibility of PyTorch with the Performance of FlashAttention, August 2024. URL <https://pytorch.org/blog/flexattention/>.
- Ramesh, A., Pavlov, M., Goh, G., Gray, S., Voss, C., Radford, A., Chen, M., and Sutskever, I. Zero-shot text-to-image generation. ArXiv, abs/2102.12092, 2021. URL <https://api.semanticscholar.org/CorpusID:232035663>.
- Razavi, A., Van den Oord, A., and Vinyals, O. Generating diverse high-fidelity images with vq-vae-2. Advances in neural information processing systems, 32, 2019.
- Rippel, O., Gelbart, M. A., and Adams, R. P. Learning ordered representations with nested dropout. ArXiv, abs/1402.0915, 2014. URL <https://api.semanticscholar.org/CorpusID:10333238>.
- Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B. High-resolution image synthesis with latent diffusion models. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, pp. 10684–10695, 2022.
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M. S., Berg, A. C., and Fei-Fei, L. ImageNet large scale visual recognition challenge. International Journal of Computer Vision, 115:211–252, 2014.

- Sadat, S., Hilliges, O., and Weber, R. M. Eliminating oversaturation and artifacts of high guidance scales in diffusion models. ArXiv, abs/2410.02416, 2024. URL <https://api.semanticscholar.org/CorpusID:273098845>.
- Shazeer, N. M. Glu variants improve transformer. ArXiv, abs/2002.05202, 2020. URL <https://api.semanticscholar.org/CorpusID:211096588>.
- Shen, J., Tirumala, K., Yasunaga, M., Misra, I., Zettlemoyer, L., Yu, L., and Zhou, C. Cat: Content-adaptive image tokenization. 2025. URL <https://api.semanticscholar.org/CorpusID:275336854>.
- Shi, J., Wu, C., Liang, J., Liu, X., and Duan, N. Divae: Photorealistic images synthesis with denoising diffusion decoder. ArXiv, abs/2206.00386, 2022. URL <https://api.semanticscholar.org/CorpusID:249240430>.
- Su, J., Ahmed, M., Lu, Y., Pan, S., Bo, W., and Liu, Y. Roformer: Enhanced transformer with rotary position embedding. Neurocomputing, 568:127063, 2024.
- Sun, P., Jiang, Y., Chen, S., Zhang, S., Peng, B., Luo, P., and Yuan, Z. Autoregressive model beats diffusion: Llama for scalable image generation. arXiv preprint arXiv:2406.06525, 2024.
- Taubman, D. S. and Marcellin, M. W. JPEG 2000: Image compression fundamentals, standards and practice. Kluwer Academic Publishers, 2001.
- Tian, K., Jiang, Y., Yuan, Z., Peng, B., and Wang, L. Visual autoregressive modeling: Scalable image generation via next-scale prediction. arXiv preprint arXiv:2404.02905, 2024.
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., et al. Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971, 2023.
- Van Den Oord, A., Vinyals, O., et al. Neural discrete representation learning. Advances in neural information processing systems, 30, 2017.
- Villegas, R., Babaeizadeh, M., Kindermans, P.-J., Moraldo, H., Zhang, H., Saffar, M. T., Castro, S., Kunze, J., and Erhan, D. Phenaki: Variable length video generation from open domain textual description. ArXiv, abs/2210.02399, 2022. URL <https://api.semanticscholar.org/CorpusID:252715594>.
- Wallace, G. K. The jpeg still picture compression standard. IEEE transactions on consumer electronics, 38(1):xviii–xxxiv, 1992.
- Wang, X. and Aitchison, L. How to set adamw’s weight decay as you scale model and dataset size. ArXiv, abs/2405.13698, 2024. URL <https://api.semanticscholar.org/CorpusID:269982015>.
- Wang, X., Zhang, X., Luo, Z., Sun, Q., Cui, Y., Wang, J., Zhang, F., Wang, Y., Li, Z., Yu, Q., et al. Emu3: Next-token prediction is all you need. arXiv preprint arXiv:2409.18869, 2024a.
- Wang, X., Zhou, X., Fathi, A., Darrell, T., and Schmid, C. Visual lexicon: Rich image features in language space. 2024b. URL <https://api.semanticscholar.org/CorpusID:274610575>.
- Xu, Y., Corso, G., Jaakkola, T., Vahdat, A., and Kreis, K. Disco-diff: Enhancing continuous diffusion models with discrete latents. ArXiv, abs/2407.03300, 2024. URL <https://api.semanticscholar.org/CorpusID:270924450>.
- Yan, W., Zhang, Y., Abbeel, P., and Srinivas, A. Videogpt: Video generation using vq-vae and transformers. arXiv preprint arXiv:2104.10157, 2021.
- Yan, W., Zaharia, M., Mnih, V., Abbeel, P., Faust, A., and Liu, H. Elastictok: Adaptive tokenization for image and video. ArXiv, abs/2410.08368, 2024. URL <https://api.semanticscholar.org/CorpusID:273323724>.
- Yang, G., Hu, J. E., Babuschkin, I., Sidor, S., Liu, X., Farhi, D., Ryder, N., Pachocki, J. W., Chen, W., and Gao, J. Tensor programs v: Tuning large neural networks via zero-shot hyperparameter transfer. ArXiv, abs/2203.03466, 2022. URL <https://api.semanticscholar.org/CorpusID:247292726>.
- Yu, J., Li, X., Koh, J. Y., Zhang, H., Pang, R., Qin, J., Ku, A., Xu, Y., Baldrige, J., and Wu, Y. Vector-quantized image modeling with improved vq-gan. arXiv preprint arXiv:2110.04627, 2021.
- Yu, J., Xu, Y., Koh, J. Y., Luong, T., Baid, G., Wang, Z., Vasudevan, V., Ku, A., Yang, Y., Ayan, B. K., Hutchinson, B., Han, W., Parekh, Z., Li, X., Zhang, H., Baldrige, J., and Wu, Y. Scaling autoregressive models for content-rich text-to-image generation. Trans. Mach. Learn. Res., 2022, 2022. URL <https://api.semanticscholar.org/CorpusID:249926846>.
- Yu, L., Lezama, J., Gundavarapu, N. B., Versari, L., Sohn, K., Minnen, D., Cheng, Y., Birodkar, V., Gupta, A., Gu, X., et al. Language model beats

diffusion-tokenizer is key to visual generation. arXiv preprint arXiv:2310.05737, 2023.

Yu, Q., Weber, M., Deng, X., Shen, X., Cremers, D., and Chen, L.-C. An image is worth 32 tokens for reconstruction and generation. arXiv preprint arXiv:2406.07550, 2024a.

Yu, S., Kwak, S., Jang, H., Jeong, J., Huang, J., Shin, J., and Xie, S. Representation alignment for generation: Training diffusion transformers is easier than you think. 2024b. URL <https://api.semanticscholar.org/CorpusID:273229262>.

Zern, J., Massimino, P., and Alakuijala, J. Webp image format. RFC, 9649:1–46, 2024. URL <https://developers.google.com/speed/webp/>.

Zha, K., Yu, L., Fathi, A., Ross, D. A., Schmid, C., Katabi, D., and Gu, X. Language-guided image tokenization for generation. ArXiv, abs/2412.05796, 2024. URL <https://api.semanticscholar.org/CorpusID:274597720>.

Zhang, B. and Sennrich, R. Root mean square layer normalization. Advances in Neural Information Processing Systems, 32, 2019.

Zhang, J., Zhan, F., Theobalt, C., and Lu, S. Regularized vector quantization for tokenized image synthesis. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 18467–18476, 2023.

Zhao, L., Woo, S., Wan, Z., Li, Y., Zhang, H., Gong, B., Adam, H., Jia, X., and Liu, T. ϵ -vae: Denoising as visual decoding. ArXiv, abs/2410.04081, 2024. URL <https://api.semanticscholar.org/CorpusID:273186399>.

附录

目录

A	FlexTok 设计选择的消融实验	16
A.1	VAE 选择的消融实验	16
A.2	重采样策略的消融实验	17
A.3	归纳偏置损失的使用	17
A.4	一维 token 的结构化与顺序诱导	19
B	FlexTok Tokenizer 表示质量评估	21
C	实现与训练细节	22
C.1	VAE 细节	22
C.2	FlexTok 细节	22
C.3	自回归模型细节	23
D	相关工作	27
E	ImageNet 补充重建与生成指标	29
F	FlexTok 推理超参数扫描	30
F.1	FlexTok 流解码器时间步扫描	30
F.2	标准无分类器引导的消融实验	30
F.3	FlexTok 归一化引导扫描	30
F.4	一维与二维 tokenizer 的无分类器引导消融	32
F.5	最终 FlexTok 推理超参数	32
G	自回归类别条件图像生成超参数扫描	33
H	自回归类别条件图像生成的模型规模	34
I	自回归文本条件图像生成的推理超参数扫描	36
J	自回归文本条件图像生成的模型规模	38
K	补充可视化结果	39
K.1	不同 token 数量下的 FlexTok 图像重建——每个 token 序列的多次采样	39
K.2	不同 token 数量和 tokenizer 规模下的 FlexTok 图像重建	41
K.3	FlexTok、TiTok 与 ALIT 的图像重建对比	43
K.4	类别条件图像生成可视化	45

K.5 文本条件图像生成可视化	49
---------------------------	----

A. FlexTok 设计选择的消融实验

我们系统探索 FlexTok 框架所提供的设计空间。具体研究 VAE 的选择、用于在 token 中诱导顺序的结构、解码器损失形式以及归纳偏置损失的使用，以最终得到一种高质量、紧凑的一维 tokenizer，能够将图像重采样为可变长度 token 序列。

默认消融设置。 除非另有说明：

- 所有模型均在分辨率为 256x256 的图像上训练。
- 我们使用 16 通道 VAE，并通过从高斯分布采样而不是直接取众数来生成 VAE 潜在空间。
- 我们使用 6 维 FSQ 量化，各维对应量化级 [8, 8, 8, 5, 5, 5]，有效词表大小为 64000。
- 在 FlexTok 编码器和解码器内部，我们对本身具有 8 倍下采样的 VAE 潜在空间采用 2x2 patch 化，因此从像素到 patch token 的有效空间下采样倍数为 16。
- 所有 FlexTok 消融模型的编码器和解码器规模均为 d12-d12，并在 ImageNet-1k (Russakovsky et al., 2014) 上训练 50B 个 patch token。一个 patch token 按一个 16x16 像素块计。
- 为评估消融模型的类别条件图像生成性能，我们在所得 token 序列上训练 393M 参数的 AR Transformer。AR 模型在 ImageNet-1k 上训练 94B 个 token (300 个 epoch)。

评估设置 我们使用一组指标评估 tokenizer 的重建与生成特性。对于图像重建，我们在 ImageNet-1k 数据集 (Russakovsky et al., 2014) 的完整验证集上计算重建 FID (rFID) (Heusel et al., 2017)、DreamSim (Fu et al., 2023) 和平均绝对误差 (MAE)。生成时，AR 模型使用 1.5 的无分类器引导尺度。对于类别条件图像生成结果，我们遵循常见做法，将 50K 个生成样本的生成 FID (gFID) 与基于 ImageNet-1k 完整训练集计算的参考统计量进行比较 (Dhariwal & Nichol, 2021)。

A.1. VAE 选择的消融实验

我们观察到 VAE 重建质量与潜在通道数量之间存在很强的相关性 (表 2)，并发现将潜在通道数从 4 增加到更高值可以显著提高 FlexTok 的重建质量 (图 10)。这一结果与“VAE 潜在通道规模应随后续潜在扩散模型规模共同扩展”的观察一致 (Esser et al., 2024)。为优化最大规模 tokenizer 的性能，我们最终选择 16 通道 VAE。

表 2: VAE 重建性能。我们在 COCO-30k 验证集 (Lin et al., 2014) 上测量 MSE 和 rFID。

模型	架构	# 潜在通道	MSE ↓	rFID ↓
SDXL VAE	SDXL VAE	4	0.0038	1.13
ours	SDXL VAE	4	0.0043	1.53
ours	SDXL VAE	8	0.0028	0.66
ours	SDXL VAE	16	0.0013	0.35




图 10: 不同 VAE 选择下的引导尺度消融。我们使用不同 VAE 训练 FlexTok d12-d12 模型，并采用自适应投影引导 (Sadat et al., 2024)，在 ImageNet-1k (Russakovsky et al., 2014) 验证集上评估。

A.2. 重采样策略的消融实验

表 3: 重采样策略消融。我们比较二维网格 token 化与一维 token 化、是否使用校正流解码器、训练噪声调度，以及是否使用辅助 REPA (Yu et al., 2024b) 损失。比较指标包括重建 MAE、DreamSim 和 rFID，以及 ImageNet-1k 类别条件生成 gFID。

Token 结构	损失形式	噪声	REPA	MAE ↓	DreamSim ↓	rFID ↓	gFID ↓
16 × 16 (2D)	MSE	-	✗	0.059	0.288	51.27	35.93
16 × 16 (2D)	校正流	mode(0.25)	✗	0.083	0.272	32.85	23.29
256 (1D)	校正流	mode(0.25)	✗	0.078	0.220	23.28	22.16
256 (1D)	校正流	均匀	✗	0.078	0.222	23.63	21.35
256 (1D)	校正流	logit-normal	✗	0.082	0.208	19.03	18.69
256 (1D)	校正流	mode(0.25)	✓	0.075	0.128	5.98	7.40

我们首先比较重采样策略（二维网格 token 化与一维寄存器 token 化），同时比较校正流解码器与仅用 MSE 优化的简单解码器。需要说明的是，这些实验均未使用任何有序化策略，相关研究将在第 A.4 节中进行。

从表 3 第 1、2 行可以看出，使用校正流解码器显著改善了 rFID 和 gFID，但 MAE 有所变差。将二维 tokenizer 替换为一维 tokenizer（第 2 行与第 3 行）后，所有指标均得到改善，其中 rFID 的提升最明显。按照 Esser et al. (2024)，我们还消融三种噪声调度：均匀噪声调度（第 4 行）、位置参数 $m = 0$ 、尺度参数 $s = 1$ 的 logit-normal 调度（第 5 行），以及尺度参数 $s = 0.25$ 的众数采样调度（第 3 行）。尽管 logit-normal 调度性能最佳，但由于最早和最晚时间步训练不足，我们观察到推理不稳定。综合考虑更好的重建表现，我们最终选择众数采样调度。

A.3. 归纳偏置损失的使用

我们观察到校正流解码器收敛较慢，因此研究使用归纳偏置损失 (Hu et al., 2023; Yu et al., 2024b)，以 (1) 缩短收敛时间，并 (2) 将强预训练视觉模型的语义归纳偏置蒸馏到 tokenizer 中，使 token 更易预测。遵循 REPA (Yu et al., 2024b)，我们训练一个三层 MLP 读取解码器第一层中二维 patch 的激活，并将其投影到 DINOv2-L 特征维度。除校正流损失外，我们还在预测特征与参考 DINOv2-L 特征之间加入权重为 1.0 的余弦相似度损失。

将表 3 最后一行与第 3 行比较可以看出，REPA 显著改善了 DreamSim、rFID 等感知重建指标以及以 gFID 衡量的生成性能。如图 12 所示，归纳偏置损失能够显著缩短达到高质量重建所需的收敛时间。这一点也体现在图 13 的视觉对比中：使用 REPA 的模型重建结果具有明显更高的保真度和更强的语义一致性。有趣的是，尽管 REPA 显著改善了重建和生成指标，却没有改善 tokenizer 训练期间重建损失的收敛（图 11）。鉴于其对下游重建和生成指标带来的显著提升，后续所有实验均使用 REPA。




图 11: REPA (Yu et al., 2024b) 消融损失曲线。我们在 ImageNet-1k 上分别训练使用和不使用 REPA 的 FlexTok d12-d12 模型。此处所示的重建损失不包含 REPA 损失项。




图 12: REPA (Yu et al., 2024b) 消融评估曲线。我们在 ImageNet-1k 上分别训练使用和不使用 REPA 的 FlexTok d12-d12 模型。评估指标均在 ImageNet-1k (Russakovsky et al., 2014) 验证集上测量。




图 13: REPA (Yu et al., 2024b) 消融模型的视觉对比。我们在 ImageNet-1k 上分别训练使用和不使用 REPA 的 FlexTok d12-d12 模型，并展示不同 token 数量下的 ImageNet-1k 验证集重建结果。

A.4. 一维 token 的结构化与顺序诱导

我们从采用 REPA 训练的一维校正流模型出发，对多种在寄存器 token 中诱导顺序的方法进行消融，对应表 3 的最后一行和表 4 的第一行。

表 4: 顺序诱导策略比较。我们对寄存器 token 上的因果掩码以及多种嵌套 dropout 变体进行消融。

Token 数量	MAE ↓			DreamSim ↓			rFID ↓			gFID ↓		
	4	32	256	4	32	256	4	32	256	4	32	256
基线	✗	✗	0.075	✗	✗	0.128	✗	✗	5.98	✗	✗	7.40
因果寄存器掩码	✗	✗	0.080	✗	✗	0.118	✗	✗	3.28	✗	✗	5.04
+ 均匀嵌套 dropout	0.268	0.148	0.080	0.522	0.275	0.132	19.97	6.48	4.01	17.99	5.26	4.83
+ “Pow2” dropout	0.209	0.159	0.088	0.440	0.323	0.175	10.39	8.09	7.22	9.51	6.63	5.78
+ “Unifpow2” dropout	0.225	0.149	0.079	0.578	0.278	0.125	30.17	6.78	3.52	28.93	5.48	4.97

首先，我们对编码器寄存器 token 上使用因果注意力掩码（见第 3.2 节）进行消融，对应表 4 第 2 行。相比无结构寄存器，因果掩码能够显著改善 rFID 和 gFID。尽管因果掩码隐式地在寄存器 token 间引入了顺序，但仅靠这一点仍无法将模型作为灵活长度 tokenizer 使用。为此，我们进一步消融三种不同的嵌套 dropout (Rippel et al., 2014) 调度（见第 3.2 节）。在“均匀嵌套 dropout”中，我们随机采样 $K_{\text{keep}} \in \{1, 2, 3, 4, \dots, K\}$ ；在“pow2”设置中，从 2 的幂中均匀采样，即 $K_{\text{keep}} \in \{1, 2, 4, 8, \dots, K\}$ ；在“unifpow2”中，则先按“均匀嵌套 dropout”采样，再向上取整到最近的 2 的幂。不同策略会对 token 序列的不同子集赋予不同训练权重。例如，采用均匀嵌套 dropout 时，每一种合法 token 数量仅在约 $\frac{1}{256}$ 的样本上得到训练，而“pow2”和“unifpow2”将可能的序列长度从 256 种减少到 9 种。“unifpow2”更偏向较长 token 序列，因此更适合需要更多 token 的图像；但由于较短序列相对训练不足，其低 token 数量下的 rFID 和 gFID 较差，而“pow2”在不同序列长度之间更加均衡（见图 14）。这种对短序列重建质量的提升，也会以完整 256-token 序列的重建和生成性能略有下降为代价。在图 15 中，我们给出所有消融模型的引导尺度扫描结果。




图 14: 不同 token 数量下 Pow2 与 Unifpow2 嵌套 dropout 调度的比较。我们在 ImageNet-1k 上使用不同嵌套 dropout 调度训练 FlexTok d12-d12，并在 ImageNet-1k 验证集上评估。Pow2 在不同序列长度之间更加均衡，而 Unifpow2 在较长序列下更有优势。




图 15: 无分类器引导消融。对所有消融模型, 我们均使用自适应投影引导 (Sadat et al., 2024) 扫描引导尺度, 评估指标在 ImageNet-1k 验证集上计算。

B. FlexTok Tokenizer 表示质量评估

本小节评估 FlexTok tokenizer 学到的表示质量。具体而言，我们对 FlexTok 编码器产生的量化寄存器 token（即作为流模型输入的 token）进行线性评估。需要强调的是，我们不使用 patch 表示，只关注量化后的寄存器 token。在线性评估中，我们在 ImageNet-1k 训练集上训练线性分类器，并在测试集上评估，同时始终冻结 tokenizer。由于线性分类器需要单一表示，我们遵循 Yu et al. (2024a) 的做法，将量化寄存器 token 拼接为每幅图像的单一特征向量。其余设置遵循 Fini et al. (2024) 的探测方案。由于 FSQ 潜变量为 6 维，最终特征向量大小为 $6 \times \text{num_register_tokens}$ 。

为了调优线性评估方案，我们在以下网格上进行超参数搜索：学习率 $\in [1 \times 10^{-3}, 5 \times 10^{-4}, 2 \times 10^{-4}]$ ，权重衰减 $\in [0.1, 0.05, 0.02]$ ，最小裁剪尺度 $\in [0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]$ 。采用搜索得到的最优超参数（学习率 5×10^{-4} 、权重衰减 0.05、裁剪尺度 $[0.4, 1.0]$ ），我们扫描寄存器 token 数量并得到图 16 所示结果。实验覆盖所有模型（FlexTok d12-d12、FlexTok d18-d18、FlexTok d18-d28），batch size 为 1024，每个实验使用 8 张 H100 或 A100 GPU。




图 16: 线性探测实验。在冻结 tokenizer 主干的情况下，改变 token 数量时的 ImageNet-1k top-1 准确率。

观察结果。这些实验很有意义，因为 tokenizer 学到的表示并不能保证线性可分。然而结果表明，这些表示确实具有线性可分性。图 7 的结果揭示了以下几点：

- 增加 token 能够提升性能：增加寄存器 token 数量会持续改善性能，这与 TiTok 中观察到的相反趋势不同。主要区别在于训练方式：TiTok 针对每一种配置（即 token 数量）分别训练模型，而我们训练一个可统一处理所有配置的模型。在我们的模型中，增加 token 时此前的 token 保持不变，例如当 $K_{\text{keep}} = 16$ 时，前 8 个 token 与 $K_{\text{keep}} = 8$ 时完全相同。因此，线性层严格获得了更多有助于提升线性可分性的信息；最坏情况下，如果新增 token 不包含有用信息，线性层也可以直接忽略它们。因此我们预期性能会随 token 数量单调提升，实验结果也验证了这一点。相比之下，TiTok 为每种 token 配置训练不同模型，因此各模型对应不同的特征空间。
- 更高的峰值性能：我们模型的最佳性能显著超过 TiTok，最优配置在 ImageNet 上达到 64.6% 的 top-1 准确率。
- 编码器与解码器规模趋势：当全部寄存器 token 激活时，更大的编码器可改善线性可分性；相反，增大解码器规模会使线性可分性略有下降。

C. 实现与训练细节

本节给出 第 C.1 节 中 VAE、第 C.2 节 中重采样器以及 第 C.3 节 中自回归模型的实现与训练细节。

C.1. VAE 细节

我们遵循 Stable Diffusion 方法 (Rombach et al., 2022) 训练一系列 VAE 模型。变分自编码器架构与 SDXL VAE (Podell et al., 2023) 相同, 但我们考察潜在维度从 4 通道增加到 8 和 16 通道的情况。判别器损失采用三层 Patch-GAN 判别器 (Isola et al., 2017), 在训练 5k 步后启用, 并与感知损失 (Dosovitskiy & Brox, 2016)、KL 损失和重建损失结合。所有 VAE 均在 DFN 数据集 (Fang et al., 2023) 图像上训练 305k 步 (40B patches), 学习率为 $1e-3$, 权重衰减 0.05, 模型 EMA 衰减 0.992, 空间下采样因子 8, KL 损失权重 $1e-6$, 判别器损失权重 0.5, 重建和感知损失权重均为 1.0, batch size 为 128。推理时, 我们通过从高斯分布采样而不是直接取众数来生成 VAE 潜在空间。

我们在 COCO 验证集上使用均方误差和重建 Fréchet inception distance (rFID) (Heusel et al., 2017) 评估训练后的 VAE (见 表 2)。结果表明, 增加潜在通道维度能够显著改善 VAE 的重建性能。由于 VAE 性能决定了后续 tokenizer 和自回归模型性能的上限, 16 通道 VAE 达到具有竞争力的 0.354 rFID 尤其重要。此外, 在这四种 VAE 变体上训练 FlexTok d12-d12 tokenizer 时, 图 10 表明, 阶段 0 选择通道数过少的 VAE 会损害阶段 1 的 FlexTok 重建性能。这一结果与 Esser et al. (2024) 一致, 因此我们使用 16 通道 VAE 训练 FlexTok, 以避免过早限制其性能上限。

C.2. FlexTok 细节

重采样 tokenizer 的详细架构和训练设置见 表 5。所有编码器和解码器均为 Transformer, 其隐藏维度 w 由层数 d 按固定宽深比 64 参数化, 即 $w = 64 \cdot d$ 。注意力头数设置为 d 。编码器和解码器均在 VAE 潜变量的 2×2 patch 上操作, 以缩短需要处理的序列长度。寄存器是形状为 $K \times d$ 的随机初始化可学习参数, 并与 VAE patch 拼接。我们使用 FlexAttention (PyTorch Team: Horace He, Driss Guessous, Yanbo Liang, Joy Dong, 2024) 构造编码器注意力掩码: 所有 patch token 可以彼此注意但不能注意寄存器; 寄存器可以注意所有 patch token; 第 i 个寄存器 token 仅当 $i \geq j$ 时才能注意第 j 个寄存器 token。

我们使用 FSQ 作为量化瓶颈, 量化级为 [8,8,8,5,5,5], 对应有效码本大小 64000。执行嵌套 dropout 时, 被丢弃的 token 由一个可学习的掩码 token 替代。

FlexTok 解码器采用校正流模型, 通过将编码器寄存器 token 与加噪 VAE 潜变量 patch 拼接来进行条件化。与编码器不同, 解码器在寄存器和 patch token 之间计算完整自注意力, 并且只输出 patch token。VAE 潜变量按照 Stable Diffusion 3 的重尾众数采样噪声调度进行采样, 尺度参数为 $s = 0.25$ 。我们使用 adaLN-Zero (Peebles & Xie, 2023) 对寄存器和图像 patch 进行条件化, 二者使用不同的 adaLN 权重集合, 但作用于相同的连续时间步嵌入。如 表 5 所示, adaLN 参数占解码器总参数的一半, 但其对整体解码器 FLOPs 的贡献可以忽略, 因为这些参数只在时间嵌入 token 上计算 (寄存器一次, 加噪 patch 一次)。如何降低这部分参数开销留待未来研究。为支持无分类器引导 (Ho, 2022), 我们以 0.2 的概率将全部编码寄存器随机替换为学习得到的空条件。解码器的预测目标为流, 见 第 3.1 节。

除校正流损失 $\mathcal{L}_{RF}$ 外, 我们还使用 REPA (Yu et al., 2024b) 加速 FlexTok 收敛。具体而言, 我们使用与解码器同维度、比例为 4.0 的三层 MLP 投影解码器第一层激活, 将其上采样到 37×37 , 并与 1024 维 DINOv2-L (Oquab et al., 2023) 特征计算余弦相似度。REPA 损失 $\mathcal{L}_{REPA}$ 与校正流损失等权, 即 $\mathcal{L} = \mathcal{L}_{RF} + 1.0 \cdot \mathcal{L}_{REPA}$ 。

重采样模型要么在 ImageNet-1k (Russakovsky et al., 2014) 上训练, 用于后续类别条件图像生成; 要么在 DFN-2B (Fang et al., 2023) 上训练, 用于自回归文本到图像模型。图像-文本描述数据集混合包含原始描述和合成描述。训练期间, 我们以 [0.8, 1.0] 的随机尺度和 [0.75, 1.3333] 的宽高比随机裁剪出 256^2 图像, 并以 0.5 的概率随机水平翻转, 最后归一化到 $[-1, 1]$ 。

所有模型总计训练至见过 200B 个 token, 其中一个 token 按一个 2×2 VAE patch 计, 即对应 16×16 像素网格。对于大小为 256^2 的图像, 每个样本对应 256 个 token。学习率在前 4B 个 token 上线性预热, 随后采用余弦衰减。模型使用 AdamW (Loshchilov & Hutter, 2017) 优化器训练; 我们利用 μP (Yang et al., 2022) 在小规模上扫描学习率和 batch size, 并将结果直接迁移到其他所有设置。需要说明的是, 我们没有针对每一种重采样设置分别扫描这些超参数, 而只在不使用 REPA、因果寄存器掩码和嵌套 dropout 的基础校正流重采样器上进行搜索。根据“带权重衰减的 AdamW 可理解为近期更新的指数移动平均 (EMA)”这一解释 (Wang & Aitchison, 2024), 我们自动设置权重衰减。具体地, 将 τ_{iter} 设置为总迭代次数 n_{iter} , 使权重衰减等价于在全部训练迭代

表 5: FlexTok 训练设置。三种不同规模重采样 tokenizer 的模型与训练配置。更多训练细节见 第 C.2 节。

配置	FlexTok d12-d12	FlexTok d18-d18	FlexTok d18-d28
编码器深度 d_{enc}	12	18	18
解码器深度 d_{dec}	12	18	28
编码器维度 w_{enc}	768	1152	1152
解码器维度 w_{dec}	768	1152	1792
编码器 Transformer 参数量	84.9M	286.7M	286.7M
解码器 Transformer 参数量	84.9M	286.7M	1.1B
解码器 adaLN (Peebles & Xie, 2023) 参数量	84.9M	286.7M	1.1B
最大寄存器数量 K		256	
寄存器注意力掩码		因果 (见 第 3.2 节)	
寄存器嵌套 dropout 模式		2 的幂: 1, 2, 4, 8, 16, 32, 64, 128, 256 (见 第 3.2 节)	
FSQ (Mentzer et al., 2023) 量化级别		[8,8,8,5,5,5]	
VAE 通道数		16	
VAE 下采样因子		8	
Patch 大小		2×2	
前馈激活函数		SwiGLU (Shazeer, 2020)	
校正流解码器		✓	
解码器 adaLN-Zero		✓	
时间嵌入 (Peebles & Xie, 2023)			
噪声众数采样		0.25	
参数 s ((Esser et al., 2024), 第 3.1 节)			
条件 dropout 概率		0.2	
REPA (Yu et al., 2024b) 层		1	
REPA (Yu et al., 2024b) 模型		DINOv2-L (Oquab et al., 2023)	
REPA (Yu et al., 2024b) 投影		与解码器同维度的三层 MLP	
REPA (Yu et al., 2024b) 损失权重		1.0	
训练长度 (n 个 token)		200B	
预热长度 (n 个 token)		4B	
预热学习率		$1e-6$	
学习率调度		余弦衰减	
模型 EMA 衰减		0.998	
优化器		AdamW (Loshchilov & Hutter, 2017)	
优化器动量		$\beta_1, \beta_2 = 0.9, 0.99$	
学习率 η		$5.62e-4$	
批大小		2048	
μP (Yang et al., 2022) 基础维度		256	
权重衰减时间尺度 τ_{iter} (Wang & Aitchison, 2024)		$n_{iter} = 381\,470$	
梯度裁剪范数		1.0	
数据集	ImageNet-1k (Russakovsky et al., 2014) 或 DFN-2B (Fang et al., 2023)		
图像分辨率	256^2		
数据增强	RandomResizedCrop, RandomHorizontalFlip, Normalize		
数据类型	bfloat16 (Burgess et al., 2019)		

上求平均；给定学习率 η ，权重衰减 λ 按 $\lambda = \frac{1}{n_{iter} \cdot \eta}$ 计算。最终模型评估时，我们还采用衰减率 0.998 的权重 EMA。精确配置见 表 5，ImageNet-1k 训练曲线见 图 17。

C.3. 自回归模型细节

类别条件和文本条件自回归 Transformer 的详细架构与训练设置分别见 表 6 和 表 7。模型的 AR 部分采用因果解码器 Transformer；与 FlexTok tokenizer 模块类似，其隐藏维度 w 根据层数 d 按固定宽深比 64 参数化，即 $w = 64 \cdot d$ ，注意力头数设为 d 。FFN 隐藏维度相对于注意力隐藏维度的 MLP 比例设为 4。




图 17: FlexTok 训练损失曲线。此处不同规模的 FlexTok 均在 ImageNet-1k (Russakovsky et al., 2014) 上训练 200B 个 token。图中给出总损失, 即 $\mathcal{L}_{\text{RF}} + \mathcal{L}_{\text{REPA}}$ 。




图 18: FlexTok 评估曲线。训练过程中, 我们定期在完整 ImageNet-1k 验证集上评估重采样器, 并给出 rFID、MAE、Inception 分数和 LPIPS。

对于类别条件模型, 我们不使用 μP (Yang et al., 2022), 而是使学习率与模型宽度成反比缩放。为缓解在 ImageNet-1k 上的过拟合, 我们在 Transformer 解码器块中的 FFN、注意力和投影模块上使用 0.1 概率的 dropout, 并对图像进行随机水平翻转。此外, 在 token 化之前, 每幅图像生成 10 个随机裁剪 (Sun et al., 2024)。对于文本条件模型, 我们则使用 μP , 所有模型规模统一采用 $1\text{e-}2$ 学习率, 不在 Transformer 解码器块中使用 dropout, 对训练图像采用正方形中心裁剪且不施加数据增强。扩展文本条件 AR Transformer 时, 学习率预热所覆盖的 token 数量设置为与模型参数量相同 (Porian et al., 2024)。

表 6: 类别条件 AR 训练设置。不同规模 AR Transformer 的模型与训练配置。

配置	AR 49M	AR 85M	AR 201M	AR 393M	AR 679M	AR 1.33B
非嵌入参数量	49M	85M	201M	393M	679M	1.33B
解码器深度 d_{dec}	10	12	16	20	24	30
解码器维度 w_{dec}	640	768	1024	1280	1536	1920
交叉注意力维度	不适用	不适用	不适用	不适用	不适用	不适用
MLP 比例				4		
最大序列长度				256		
注意力掩码				因果		
词表大小				64,000		
前馈激活函数			SwiGLU (Shazeer, 2020)			
位置编码			学习式嵌入			
条件 dropout 概率				0.1		
FFN、注意力与投影 dropout 概率				0.1		
训练长度 (n 个 token)	94B (300 个 epoch)					
预热长度 (n 个 token)	9.4B					
初始预热学习率	1e-6					
学习率调度	余弦衰减					
优化器	AdamW (Loshchilov & Hutter, 2017)					
优化器动量	$\beta_1, \beta_2 = 0.9, 0.95$					
学习率 η	1.2E-3	1E-3	7.5E-4	6E-4	5E-4	4E-4
最终学习率	$\eta \times 1E-2$					
批大小	1024					
μP (Yang et al., 2022) 基础维度	不适用					
权重衰减	0.05					
权重衰减时间尺度 τ_{iter} (Wang & Aitchison, 2024)	不适用					
梯度裁剪范数	1.0					
数据集	ImageNet-1k (Russakovsky et al., 2014)					
图像分辨率	256 ²					
数据增强	10 个候选 RandomResizedCrop, RandomHorizontalFlip, Normalize					
数据类型	bfloat16 (Burgess et al., 2019)					

表 7: 文本条件 AR 训练设置。不同规模 AR Transformer 的模型与训练配置。

配置	AR 113M	AR 382M	AR 1.15B	AR 3.06B
非嵌入参数量	113M	382M	1.15B	3.06B
解码器深度 d_{dec}	12	18	26	36
解码器维度 w_{dec}	768	1152	1664	2304
交叉注意力维度	12	18	26	36
MLP 比例		4		
最大序列长度		256		
注意力掩码		因果		
词表大小		64,000		
前馈激活函数		SwiGLU (Shazeer, 2020)		
位置编码		学习式嵌入		
条件 dropout 概率		0.1		
FFN、注意力与投影 dropout 概率		0.0		
训练长度 (n 个 token)		284B		
训练 FLOPs	1.93E+20	6.39E+20	1.90E+21	5.00E+21
预热长度 (n 个 token)				
初始预热学习率		1e-6		
学习率调度		余弦衰减		
优化器		AdamW (Loshchilov & Hutter, 2017)		
优化器动量		$\beta_1, \beta_2 = 0.9, 0.95$		
学习率 η		1e-2		
最终学习率		$\eta \times 1E-2$		
批大小		8192		
μP (Yang et al., 2022) 基础维度		256		
权重衰减		0.05		
权重衰减时间尺度 τ_{iter} (Wang & Aitchison, 2024)		$n_{iter} = 135\,594$		
梯度裁剪范数		1.0		
数据集		DFN-2B (Fang et al., 2023)		
图像分辨率		256^2		
数据增强		不适用		
数据类型		bfloat16 (Burgess et al., 2019)		

D. 相关工作

图像 token 化。 Token 化的目标是将高维图像转换为更紧凑的 token 表示序列，从而使扩散与流 (Rombach et al., 2022; Podell et al., 2023; Ma et al., 2024; Esser et al., 2024; Yu et al., 2024b)、掩码 (Chang et al., 2022; 2023; Li et al., 2022; Lu et al., 2022; 2023; Mizrahi et al., 2023; Bachmann et al., 2024) 或自回归 (Chen et al., 2020; Ramesh et al., 2021; Yu et al., 2022; Sun et al., 2024) 图像建模更加易于处理。通常，这些 token 通过带离散瓶颈 (Van Den Oord et al., 2017; Razavi et al., 2019) 或连续正则化瓶颈 (Rombach et al., 2022) 的自编码器目标学习。此外，辅助感知损失和判别器损失 (Esser et al., 2021; Yu et al., 2021) 常用于忽略不可感知细节，而潜在偏置损失 (Hu et al., 2023) 已被证明有助于下游 token 预测。在离散情况下，向量量化 (VQ) (Van Den Oord et al., 2017) 长期以来一直是事实标准，但 LFQ (Yu et al., 2023) 和 FSQ (Mentzer et al., 2023) 等近期技术展现出很有潜力的规模扩展趋势。

采用校正流解码的 tokenizer。 图像 tokenizer 的核心属性之一，是能够从高度压缩的 token 中重建感知上合理的图像。虽然判别器损失 (Esser et al., 2021) 常用于实现这一目标，但其训练过程往往难以稳定 (Yu et al., 2024a)。因此，与其他工作 (Shi et al., 2022; Mizrahi et al., 2023; Bachmann et al., 2024; Xu et al., 2024; Zhao et al., 2024) 类似，我们选择将解码器训练为校正流 (Liu et al., 2022) 模型。该方法已在同时具有粗粒度和细粒度条件的可扩展图像生成中取得成功，而这一性质尤其适合能够处理广泛条件具体程度的 FlexTok。

结构化 token 化。 目前，上述大多数图像 token 化方法都会将图像投影为固定大小的二维网格。VAR (Tian et al., 2024) 和 Infinity (Han et al., 2024) 等方法将图像投影为结构化多尺度潜在表示，并展现出显著的规模扩展趋势；TiTok (Yu et al., 2024a)、TexTok (Zha et al., 2024) 和 DisCo-Diff (Xu et al., 2024) 则探索彻底去除二维网格，将图像投影为无结构但高度紧凑的一维序列。不过，图像表示所使用的 token 数量在 TiTok 中仍是固定的，在 Infinity 中则依赖图像分辨率。

结构化与自适应 token 化。 为解决 token 序列长度完全由图像高宽而非图像复杂度决定的问题，一系列同期工作提出了自适应 token 化方法：

- ElasticTok (Yan et al., 2024) 是一种联合图像与视频 tokenizer，在训练期间于预设的最小和最大 token 数量之间执行嵌套 dropout。作者指出，由于更低取值会导致不稳定，最小下界被设置为 128 或 256。相比 ElasticTok，我们观察到 FlexTok 即使下降到单个 token 也能稳定训练。此外，通过使用校正流目标训练解码器，FlexTok 在任意 token 数量下均可重建高保真图像。相比之下，ElasticTok 仅使用 MSE 和 LPIPS 损失训练，因此需要显著更多的 token 才能获得高感知质量的重建。
- ALIT (Duggal et al., 2024) 提出一种自适应长度 tokenizer，通过循环方式将图像编码为不断增长的 token 序列，并可动态停止该过程，从而得到自适应大小的图像表示。相比 ALIT，FlexTok 只需一次前向传播即可编码图像，并通过因果掩码与嵌套 dropout 高效地强制形成顺序。由于 ALIT 的 tokenizer 仅在 ImageNet-1k 的 100 类子集上训练，且未在生成任务上评估，其规模扩展和生成性质尚未得到充分实验验证。相比之下，我们同时扩展 FlexTok 与下游 AR 模型，并展示出较强的生成建模能力。
- One-D-Piece (Miwa et al., 2025) 在架构上与 TiTok (Yu et al., 2024a) 和 FlexTok 类似，同样使用寄存器编码器和解码器，并在 1 到 256 个 token 的序列上采用嵌套 dropout 训练。尽管 One-D-Piece 在 token 数量较多时能够取得良好重建指标，但与 FlexTok 不同，其在 token 数量较少时无法生成合理图像。此外，它与 TiTok 一样需要两阶段训练，而 FlexTok 的阶段 1 采用端到端训练。与 ElasticTok 和 ALIT 类似，作者也没有评估使用 One-D-Piece token 训练生成模型的效果。
- ViLex (Wang et al., 2024b) 使用预训练文本编码器和扩散模型，学习可变大小的“文本 token”集合来编码给定图像。类似 textual inversion (Gal et al., 2022)，这些软 token 可以与图像提示结合以生成新图像。FlexTok 的目标则更侧重于学习通用的由粗到细 token 序列，使短序列具有高度语义性、长序列具有高度细节性。我们认为，使用预训练扩散模型作为解码器是很有潜力的未来研究方向。
- CAT (Shen et al., 2025) 提出一种嵌套 VAE 架构，可将图像自适应压缩为空间下采样 8x、16x 和 32x 的表示。与 FlexTok 的离散一维表示相比，这些 token 网格是二维且连续的。

有序表示学习。 除图像生成外，有序表示学习也是一个长期研究方向。嵌套 dropout (Rippel et al., 2014) 通过从一侧均匀丢弃潜变量来学习可变大小的瓶颈表示；Matryoshka Representation Learning (Kusupati et al., 2022) 提出从 2 的幂中采样表示维度，并使用权重共享的解码器分别解码；Matryoshka Multimodal Models (Cai

et al., 2024) 则将二维视觉编码器表示自适应池化为更小的二维网格；UViM (Kolesnikov et al., 2022) 提出使用嵌套 dropout 学习更鲁棒、也更易由下游语言模型建模的编码。

可变码率压缩。 在有损图像压缩中，如何在压缩强度（码率）与重建性能（失真）之间进行权衡一直是长期研究的问题。经典有损图像压缩编解码器 (Wallace, 1992; Zern et al., 2024; Taubman & Marcellin, 2001) 以及近期神经压缩算法 (Mentzer et al., 2020; El-Nouby et al., 2022; Hoogeboom et al., 2023) 都能够让用户有效选择这一权衡，并可将简单图像压缩为比复杂图像更小的文件。经典 JPEG 图像按照光栅扫描顺序传输和解码，而渐进式 JPEG (Wallace, 1992) 等渐进方案则以由粗到细的方式组织图像，使用户能够非常快速地重建出图像的低质量版本。

E. ImageNet 补充重建与生成指标

为补充图 5 中给出的 ImageNet-1k 重建指标 (rFID、MAE 和 DreamSim)，我们在表 8 中进一步给出逐图像重建指标，包括在 ImageNet-1k 验证集上测量的 PSNR、SSIM 和 LPIPS。对于图 7 (右) 和图 9 中的类别条件生成结果，我们也在表 9 中补充 CLIP 分数、gFID、sFID、Inception 分数、精确率和召回率，这些指标均相对于完整 ImageNet-1k 训练集进行测量。

表 8: FlexTok d18-d28 在 ImageNet-1k 上的重建指标。对于在 ImageNet-1k 上训练的最大规模 FlexTok d18-d28 模型，我们给出完整验证集上的重建指标，包括衡量分布级差异的重建 FID，以及像素空间 (MAE、PSNR、SSIM) 和特征空间 (LPIPS、DreamSim) 的逐图像失真。词表大小为 64 000 时，每个 token 占用 2 字节存储空间。

# token	# 字节	rFID ↓	MAE ↓	PSNR ↑	SSIM ↑	LPIPS ↓	DreamSim ↓
1	2	4.01	0.273	9.35	0.187	0.701	0.546
2	4	3.09	0.237	10.25	0.222	0.651	0.494
4	8	2.43	0.197	11.51	0.254	0.582	0.417
8	16	1.90	0.185	11.90	0.269	0.532	0.321
16	32	1.61	0.154	13.05	0.304	0.462	0.271
32	64	1.45	0.134	13.96	0.330	0.407	0.227
64	128	1.37	0.126	14.34	0.343	0.380	0.207
128	256	1.20	0.102	15.90	0.407	0.293	0.158
256	512	1.08	0.081	17.70	0.489	0.219	0.114

表 9: 搭配 FlexTok d18-d28 的 1.33B 类别条件 AR 模型在 ImageNet-1k 上的生成指标。我们给出一个在 FlexTok d18-d28 token 上训练的 1.33B 类别条件 AR 模型的生成指标。生成 FID、sFID、Inception 分数、精确率和召回率使用 50k 个生成样本，并与完整 ImageNet-1k 训练集统计量比较计算；CLIP 分数则在完整验证集上计算。

# token 数	CLIP 分数 ↑	gFID ↓	sFID ↓	IS ↑	精确率 ↑	召回率 ↑
1	26.84	3.14	6.54	236.47	0.83	0.53
2	27.10	2.51	5.33	238.07	0.82	0.57
4	27.51	2.00	4.86	226.77	0.80	0.60
8	28.84	1.82	4.53	266.48	0.82	0.61
16	29.12	1.75	4.32	277.45	0.82	0.61
32	29.10	1.71	4.46	284.99	0.82	0.61
64	29.14	1.76	4.53	286.40	0.82	0.61
128	29.03	1.89	5.24	275.63	0.82	0.61
256	28.94	2.45	6.76	258.33	0.80	0.61

F. FlexTok 推理超参数扫描

对于训练完成的 FlexTok 模型，我们扫描与校正流解码器相关的不同推理超参数，例如 图 19 中的去噪步数，以及 图 21 中使用自适应投影引导 (APG) (Sadat et al., 2024) 时的无分类器引导尺度。我们还在 图 20 中给出标准引导形式下的尺度扫描，并在 图 22 中比较最大规模一维和二维 tokenizer 的引导尺度。

F.1. FlexTok 流解码器时间步扫描

针对不同 token 数量，我们在 FlexTok d18-d28 （在 ImageNet-1k 上训练）上将去噪步数从 1 扫描到 100。默认引导尺度设为 7.5，并使用 APG (Sadat et al., 2024)。如 图 19 所示，当去噪超过 25 步后，重建质量指标的边际收益明显降低。rFID 和 DreamSim 基本进入平台期，而相对于原始图像的平均绝对误差仍继续增大，尤其是在 token 数量较少时。后续所有消融实验均使用 25 个去噪步，并将其作为所有模型规模的默认值，因为这一设置在推理速度与质量之间取得了良好平衡。




图 19: 推理去噪步数消融。我们在 FlexTok d18-d28 （在 ImageNet-1k 上训练）上扫描推理步数，发现 25 个去噪步能够在推理速度与质量之间取得良好平衡。

F.2. 标准无分类器引导的消融实验

我们发现，在流匹配解码器中使用标准无分类器引导 (Ho, 2022) 会形成非常狭窄的最优重建性能区间，而且该区间高度依赖于提供给解码器的 token 数量（见 图 20）。因此，如 第 F.3 节 所讨论，我们改用 APG (Sadat et al., 2024)。




图 20: 标准无分类器引导消融。我们对 FlexTok d18-d28 （在 ImageNet-1k 上训练）扫描引导尺度，发现最优引导尺度区间较窄，并且会随使用的 token 数量发生显著变化。

F.3. FlexTok 归一化引导扫描

我们希望避免不同 FlexTok token 数量对应的最优引导尺度差异过大。如 第 F.2 节 所示，标准无分类器引导可能产生狭窄的最优区间。因此，我们探索自适应投影引导 (APG) (Sadat et al., 2024) 等归一化引导方案。超参数设置为重缩放阈值 $r = 2.5$ 、平行分量 $\eta = 0$ 、动量 $\beta = -0.5$ ，并扫描引导尺度。与标准引导相比，APG (Sadat et al., 2024) 得到的最优性能区间更加平缓，在不同 token 数量间更加一致，并且整体 rFID 更优。

较小 FlexTok 模型的最优区间相比大模型一致性更弱，且对应最优引导值更高。无论模型规模如何，随着引导尺度增大，DreamSim 均先改善后进入平台，而 MAE 略有变差。




图 21: 自适应投影引导 (Sadat et al., 2024) 消融。我们针对不同 FlexTok 模型规模和 token 数量扫描引导尺度，结果表明 APG 的引导尺度性能区间比标准引导更加平滑。

F.4. 一维与二维 tokenizer 的无分类器引导消融

对于最大规模 tokenizer FlexTok d18-d28（在 DFN-2B 上训练），我们在 COCO 30.5k 验证集上将其无分类器引导性能区间与受控二维网格 tokenizer 基线进行比较。两个模型均使用 APG (Sadat et al., 2024)。如图 22 所示，在各个引导尺度下，一维 tokenizer 的 rFID 和 DreamSim 均大幅优于二维基线，但二维网格 tokenizer 在 MAE 上表现更好。




图 22: 一维与二维 FlexTok d18-d28 的引导尺度消融。我们对 FlexTok d18-d28（在 DFN-2B 上训练）及受控二维 tokenizer 基线扫描 APG 引导尺度。一维 FlexTok d18-d28 模型使用完整 256 个 token 进行评估。

F.5. 最终 FlexTok 推理超参数

基于上述观察，我们为不同模型规模和训练数据集确定最终推理超参数，并在后续所有图像生成实验中使用这些设置。ImageNet-1k tokenizer 的配置见 表 10，DFN-2B tokenizer 的配置见 11。需要指出的是，扩散与流模型中常用的时间步蒸馏和引导尺度蒸馏技术同样适用于 FlexTok 解码器，我们预计这些方法能够显著降低解码器运行的计算需求。

表 10: ImageNet-1k FlexTok 推理设置。在 ImageNet-1k 上训练的三种不同规模 tokenizer 所采用的推理配置。

配置	FlexTok d12-d12	FlexTok d18-d18	FlexTok d18-d28
# 去噪步数	25	25	25
自适应投影引导 (APG) (Sadat et al., 2024)	是	是	是
解码器引导尺度	15	7.5	7.5

表 11: DFN FlexTok 推理设置。在 DFN-2B 上训练的模型所采用的 tokenizer 推理配置。

配置	FlexTok d18-d28	二维网格 d18-d28
# 去噪步数	25	25
自适应投影引导 (APG) (Sadat et al., 2024)	是	是
解码器引导尺度	7.5	5.0

G. 自回归类别条件图像生成超参数扫描

对于在 FlexTok tokenizer 上训练的分类条件 AR Transformer，我们扫描多种推理阶段超参数。AR 模型中的无分类器引导通过更新预测 logits $\hat{x}$ 实现，即 $\hat{x} = x_{\text{uncond}} + s \cdot (x_{\text{cond}} - x_{\text{uncond}})$ ，其中 x_{cond} 和 x_{uncond} 分别表示有条件和无条件输入时的 logits。对于训练完成的 1.33B AR 模型和 FlexTok d18-d28，我们发现不使用引导，即 CFG 尺度 $s = 1.0$ 时，无论 top-k 采样设置或解码到图像空间前生成的 token 数量如何，都能获得最佳 gFID (图 23和24)。无需引导即可获得最优 gFID，是基于 FlexTok tokenizer 的 AR 模型区别于已有方法的一个特征。例如，LlamaGen 类别条件模型的最优 CFG 值为 2.0 (Sun et al., 2024)。这种性质可能来源于 tokenizer 中因果掩码和嵌套 dropout 所引入的有序结构。无需 CFG 还能够显著节省推理计算，尤其是无需将 batch 扩大一倍以容纳无条件样本。除对 CFG 尺度的这一特殊依赖外，我们还发现提高 top-k 采样阈值可以改善 gFID；若追求最优生成 FID，则应完全不使用 top-k 采样。




图 23: 搭配 FlexTok d18-d28 的 1.33B 类别条件 AR 模型: 引导与 top-K 消融。gFID 相对于完整 ImageNet-1k 训练集统计量计算。




图 24: 搭配 FlexTok d18-d28 的 1.33B 类别条件 AR 模型: 引导与 token 数量消融。gFID 相对于完整 ImageNet-1k 训练集统计量计算。

H. 自回归类别条件图像生成的模型规模

在类别条件模型中增大 AR 模型规模后，我们观察到训练损失持续改善（图 25）。采用第 G 节中得到的最优推理参数，即不使用 CFG 和 top-k 采样，我们在固定 FlexTok d18-d28 tokenizer 的情况下评估扩展 AR 模型规模的影响。图 26 表明，当只生成少量 token 时，生成性能几乎不依赖模型规模；但序列越长，较大的 AR 模型越能减少 token 解码误差。当生成完整 256 个 token 时，增大 AR 模型规模能够显著改善 gFID。需要指出的是，即使对于本文研究的最大 AR 模型（1.33B 参数），当解码 token 数超过约 128 后，gFID 仍出现轻微退化。




图 25: 自回归类别条件图像生成损失曲线。图中不同规模 AR 模型均使用在 ImageNet-1k 上训练的 FlexTok d18-d28 tokenizer，并在 ImageNet-1k 上训练 94B 个 token。




图 26: 自回归类别条件图像生成模型扩展。左图给出不同 AR 模型规模在不同生成 token 数量下的 gFID；右图给出生成 256 个 token 时 gFID 随 AR 模型参数数量的变化。gFID 相对于完整 ImageNet-1k 训练集统计量计算。所有 AR 模型均使用在 ImageNet-1k 上训练的 FlexTok d18-d28 tokenizer。生成时采用第 G 节中给出的最优推理参数。

增大 tokenizer 规模能够显著改善生成质量（图 27）。在固定 AR 模型规模为 1.33B 时，我们将 tokenizer 从 FlexTok d12-d12 扩展到 FlexTok d18-d28，并观察到 gFID 持续改善。对于部分 tokenizer 规模，tokenizer 自身的重建质量已经成为生成模型性能的上限。




图 27: 自回归类别条件图像生成中的 FlexTok tokenizer 规模扩展。左图给出使用不同规模 FlexTok tokenizer 训练的 1.33B AR 模型在不同生成 token 数量下的 gFID; 右图给出生成 256 个 token 时 gFID 随 FlexTok tokenizer 参数数量的变化。gFID 相对于完整 ImageNet-1k 训练集统计量计算。生成时采用 第 G 节 中的最优推理参数。

I. 自回归文本条件图像生成的推理超参数扫描

对于使用 FlexTok tokenizer 训练的文本条件 AR Transformer，我们扫描无分类器引导尺度和解码 token 数量。对于训练完成的 3.06B AR 模型和 FlexTok d18-d28，我们发现无分类器引导能够改善所有生成序列长度下的 gFID（图 28）。这与类别条件的 FlexTok 模型不同，后者使用 CFG 会损害 gFID。造成这种差异的因素可能包括条件复杂度不同，以及 DFN 训练集与 COCO 验证集之间存在分布偏移。除改善 gFID 外，我们还发现 CLIPScore 会随着引导强度增加而提高。

我们发现，在各种生成 token 数量下，CFG 尺度 2.5 都能使 gFID 接近最优。采用该 CFG 尺度时，随着生成 token 数量增加，gFID 先急剧下降，随后逐渐升高（图 29）。相比之下，以 CLIPScore 衡量的文本-图像对齐则会随着 token 数量增加持续改善。




图 28: 搭配 FlexTok d18-d28 的 3.06B 文本条件 AR 模型: 引导与 token 数量消融。在不同 token 数量下，相对于 COCO 验证集测量 gFID（左）和 CLIPScore（右）。




图 29: 搭配 FlexTok d18-d28 的 3.06B 文本条件 AR 模型: 图像生成性能随 token 数量的变化。所有指标均在生成时使用 CFG 尺度 2.5。左图给出在 DFN 上训练的 FlexTok d18-d28 在 COCO 验证集上的 rFID；中图和右图分别给出 AR 图像生成在 COCO 验证集上的 gFID 和 CLIPScore 随生成 token 数量的变化。

图 30 表明，基于二维网格的 tokenizer 的评估指标对 CFG 尺度具有类似依赖关系。我们选择 CFG 尺度 2.5，以在 gFID 与 CLIPScore 之间取得平衡。同时，该尺度与基于 FlexTok 的模型保持一致，使两种方法能够进行公平比较。




图 30: 搭配二维网格 tokenizer 的 3.06B 文本条件 AR 模型：引导消融。在不同 token 数量下，相对于 COCO 验证集测量 gFID (左) 和 CLIPScore (右)。

J. 自回归文本条件图像生成的模型规模

采用第 I 节中得到的最优推理参数，我们固定 FlexTok d18-d28 tokenizer，评估扩展 AR 模型规模的影响。将模型从 113M 扩展到 3.06B 参数后，无论使用 FlexTok 还是二维网格 tokenizer，最终损失都会降低（图 31 和 32）。当生成完整 256 个 token 时，增大 AR 模型规模能够显著改善 gFID（图 33）。




图 31: FlexTok 自回归文本条件图像生成损失曲线。图中不同规模的 AR 模型均使用在 DFN 上训练的 FlexTok d18-d28 tokenizer，并在 DFN 上训练 284B 个 token。




图 32: 二维网格 tokenizer 的自回归文本条件图像生成损失曲线。图中不同规模的 AR 模型均在 DFN 上训练 284B 个 token，并使用在 DFN 上训练的二维网格 tokenizer。




图 33: 自回归文本条件图像生成模型扩展。图中给出不同模型规模的 gFID 随 AR 模型参数数量的变化。在 AR 生成过程中，我们生成 256 个 token，以便比较 FlexTok 与二维网格 tokenizer，并采用第 I 节中给出的最优推理参数。gFID 相对于 COCO 验证集计算。所有 AR 模型均使用在 DFN 上训练的 tokenizer。